



图书分类号: TP181

学校代码: 10615

西南石油大学

专业学位硕士学位论文

(全日制)

论文题目 基于图神经网络的跨
域序列推荐算法的研
究与应用

学位类别 工程硕士

专业学位领域 软件工程

研究方向 推荐算法

研究生姓名 陈琴

学号 202122000516

校内导师姓名 耿新宇

校外导师姓名

论文完成时间: 2024 年 3 月

摘要

随着社会经济与网络技术的飞速发展,推荐系统已经成为电子商务、社交媒体等网络平台不可或缺的一部分。序列推荐方法从用户的行为序列中捕捉用户动态偏好在推荐系统中取得了很大的成功,但这些方法在真实应用中依然存在一些问题,如数据稀疏、冷启动问题等。跨域序列推荐可通过引入相对丰富的源域数据来缓解这些问题。然而,现有的跨域序列推荐方法大多独立于领域内获取用户偏好,忽略了不同领域序列的项目转换模式,即用户在一个领域中的交互可能会影响在其它领域中的下一次交互。其次,忽视了项目间的时间间隔信息,这是序列推荐中一个关键因素,因为它有助于捕捉用户意图随时间的变化。此外,基于图卷积的跨域序列推荐方法大多平等地对待不同领域中的项目节点,不区分重要程度容易在跨域推荐中出现负迁移问题。因此为解决上述问题,本文针对目前跨域序列推荐方法存在的问题做出了相应的改进。本文的主要研究工作如下:

(1) 针对跨域序列推荐未考虑领域项目转换模式以及交互时间间隔问题,提出了基于时间感知的图神经网络跨域推荐(Time-Aware Graph Neural Network for Cross-Domain Recommendation, TAGNN)模型。首先将用户在不同领域的交互序列按照时间顺序构建跨域序列,即分别构建用户序列图和跨域全局图,采用门控图神经网络(GGNN)作为用户序列图编码器选择性地聚合、更新节点嵌入,提取用户动态序列信息;利用图卷积网络学习跨域全局图中领域间的项目协作信息。其次,为考虑项目时间间隔信息并增强序列的表征学习,提出了时间间隔注意力编码器(TiAttEncoder),将时间间隔信息融入注意力模块中学习项目的交互特征。然后,为了权衡跨域序列中项目对目标域的重要性,提出了基于对比学习的辅助任务。具体的,利用 softmax 函数计算跨域序列中源域项目对目标域的相关性,相关性小于 0.5 的项目用掩码替换,经过替换后得到对比序列,再将目标域序列与对比序列进行对比学习,通过最大化域内序列和跨域序列来增强它们之间的相关性。最后,联合域内推荐、跨域推荐任务以及辅助任务对模型进行优化。通过在亚马逊的两组数据集 Movie-Book、Food-Kitchen 上对该模型进行实验评估,证明了 TAGNN 模型性能优于当前流行的基线模型,且同时进行消融实验等证明了各个模块的有效性。

(2) 针对当前基于图卷积的跨域推荐忽略了领域节点重要程度的问题,提出了基于注意力和时间感知的图神经网络跨域推荐(Attention and Time-Aware Graph Neural Network for Cross-Domain Recommendation, ATAGNN)模型。在跨域全局图中,为区分不同领域项目对用户偏好的影响,提出层级注意力图卷积网络(Graph Convolutional Networks with Hierarchical Attention, HAGCN),通过层级注意力从节点级和领域级自动区分领域间项目节点的重要性,以学习项目嵌入。为更好地结合跨域信息,将用户序

列图和跨域全局图学习到的图嵌入进行聚合，并将得到的聚合嵌入和跨域图嵌入通过序列编码器得到目标域和跨域中的用户顺序偏好，最后通过 softmax 函数得到最终推荐概率。通过在亚马逊两组数据集上进行的大量实验，验证了 ATAGNN 模型的有效性。

(3) 基于本文提出的 ATAGNN 模型，以电影图书为研究场景，设计并实现了一个跨域推荐系统。该系统实现了用户对电影、图书网站的基本需求，包括搜索、推荐、评分等功能，且能够根据用户在两个领域的历史交互数据，为用户推荐感兴趣的电影或图书，并可依据用户的反馈信息进行调整和优化，从而不断地提升推荐效果。

关键词：跨域序列推荐；图神经网络；注意力机制；对比学习

Abstract

With the rapid development of social economy and network technology, recommendation systems have become an indispensable part of online platforms such as e-commerce and social media. Sequence recommendation methods capture users' dynamic preferences from user behavior sequences and have achieved great success in recommendation systems. However, these methods still have some problems in real applications, such as data sparseness and cold start problems. Cross-domain sequential recommendation can alleviate these problems by introducing relatively rich source domain data. However, most of the existing cross-domain sequential recommendation methods obtain user preferences independently of the domain and ignore the item conversion patterns of different domain sequences, that is, the user's interaction in one domain may affect the next interaction in other domains. Secondly, the time interval information between items is ignored, which is a key factor in sequence recommendation because it helps capture the changes in user intention over time. In addition, most cross-domain sequential recommendation methods based on graph convolution treat project nodes in different fields equally, and do not distinguish the importance and are prone to negative transfer problems in cross-domain recommendation. Therefore, in order to solve the above problems, this thesis makes corresponding improvements to the problems existing in the current cross-domain sequential recommendation methods. The main research work of this article is as follows:

(1) Aiming at the problem that cross-domain sequential recommendation does not consider the domain item conversion mode and interaction time interval, a Time-Aware Graph Neural Network for Cross-Domain Recommendation (TAGNN) model is proposed. First, the user interaction sequences in different fields are constructed in chronological order across domains, that is, the user sequence graph and the cross-domain global graph are constructed respectively, and the gated graph neural network (GGNN) is used as the user sequence graph encoder to selectively aggregate and update Node embedding to extract user dynamic sequence information. Using graph convolutional networks to learn inter-domain project collaboration information in cross-domain global graphs. Then, in order to consider the time interval information of the items and enhance the representation learning of the sequence, a time interval attention encoder (TiAt-Encoder) is proposed, which integrates the time interval information into the attention module to learn the interactive features of the items. In addition, in order to weigh the importance of items in cross-domain sequences to the target domain, an auxiliary task based on contrastive learning is proposed. Specifically, the softmax function is used to calculate the correlation between the source domain items in the cross-domain sequence and the target domain. The items

whose correlation is less than the threshold are replaced with masks. After replacement, the comparison sequence is obtained, and then the target domain sequence and the comparison sequence are compared and learned. , to enhance the correlation between intra-domain sequences and cross-domain sequences by maximizing them. Finally, the model is optimized by combining intra-domain recommendation, cross-domain recommendation tasks and auxiliary tasks. Through experimental evaluation of the model on two sets of Amazon data sets, Movie-Book and Food-Kitchen, it was proved that the performance of the TAGNN model is better than the current popular baseline model, and ablation experiments were conducted at the same time to prove the effectiveness of each module.

(2) In order to solve the problem that the current cross-domain recommendation based on graph convolution ignores the importance of domain nodes, an Attention and Time-Aware Graph Neural Network for Cross-Domain recommendation(ATAGNN) is proposed. In the cross-domain global graph, in order to distinguish the impact of items in different fields on user preferences, a hierarchical attention graph convolutional network (HAGCN) is proposed to automatically distinguish between fields from the node level and the field level through hierarchical attention. Importance of item nodes to learn item embeddings. In order to better combine cross-domain information, the user sequence graph and the graph embedding learned from the cross-domain global graph are aggregated, and the resulting aggregated embedding and cross-domain graph embedding are passed through the sequence encoder to obtain users in the target domain and cross-domain Sequential preference, and finally the final recommendation probability is obtained through the softmax function. Through a large number of experiments on two sets of Amazon data sets, the effectiveness of the ATAGNN model was verified.

(3) Based on the ATAGNN model proposed in this thesis, a cross-domain recommendation system is designed and implemented using movies and books as the research scenario. This system realizes the basic needs of users for movie and book websites, including search, recommendation, rating and other functions, and can recommend movies or books of interest to users based on their historical interaction data in the two fields, and can also recommend movies or books of interest to users based on their historical interaction data in the two fields. Adjust and optimize the feedback information to continuously improve the recommendation effect.

Key words: Cross-domain sequential recommendation; Graph neural network; Attention mechanism; Comparative learning

目 录

第 1 章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 序列推荐算法.....	2
1.2.2 跨域推荐算法.....	4
1.2.3 基于图神经网络推荐算法.....	5
1.3 本文的主要创新点.....	6
1.4 本文的组织架构.....	7
第 2 章 相关理论与技术	9
2.1 跨域推荐概念.....	9
2.1.1 域的定义.....	9
2.1.2 跨域推荐方法.....	10
2.2 注意力机制.....	11
2.3 图神经网络技术.....	14
2.3.1 图卷积神经网络.....	15
2.3.2 门控图神经网络.....	16
2.3.3 图注意力网络.....	16
2.4 对比学习.....	18
2.5 本章小结.....	19
第 3 章 基于时间感知的图神经网络跨域推荐模型	20
3.1 引言.....	20
3.2 模型构建.....	21
3.2.1 模型结构.....	21
3.2.2 输入与嵌入层.....	22
3.2.3 用户序列图.....	23
3.2.4 跨域全局图.....	24
3.2.5 序列表示模块.....	24
3.2.6 跨域偏好对比学习和模型预测.....	26
3.3 模型性能验证.....	28
3.3.1 数据集.....	28
3.3.2 评价指标.....	29
3.3.3 实验环境与设置.....	29
3.3.4 对比实验结果及分析.....	30
3.3.5 消融实验.....	33

3.3.6 超参数学习.....	34
3.4 本章小结.....	36
第4章 基于注意力和时间感知的图神经网络跨域推荐	37
4.1 引言.....	37
4.2 模型构建.....	38
4.2.1 层级注意力图卷积网络.....	38
4.2.2 图嵌入聚合.....	41
4.2.3 模型整体架构.....	41
4.3 模型性能验证.....	43
4.3.1 实验环境与设置.....	43
4.3.2 模型性能对比.....	43
4.3.3 消融实验.....	44
4.3.4 超参数学习.....	46
4.4 本章小结.....	47
第5章 跨领域推荐系统的设计与实现	48
5.1 需求分析.....	48
5.1.1 功能需求分析.....	48
5.1.2 非功能性需求分析.....	49
5.2 系统设计.....	49
5.2.1 系统架构设计.....	49
5.2.2 功能模块设计.....	50
5.2.3 数据库设计.....	52
5.3 系统实现.....	54
5.3.1 开发环境.....	54
5.3.2 系统页面展示.....	54
5.4 系统测试.....	57
5.4.1 功能性测试.....	58
5.4.2 性能测试.....	59
5.5 本章小结.....	60
第6章 总结与展望	61
6.1 全文总结.....	61
6.2 未来研究展望.....	62
参考文献.....	63

第 1 章 绪论

本章是论文的绪论，旨在对跨域序列推荐任务进行简单的介绍和阐述。具体而言，探讨了跨域序列推荐任务的背景和意义，介绍了国内外研究现状，最后给出了本文的主要创新点和论文的组织架构。

1.1 研究背景及意义

在信息化时代，大数据、互联网和人工智能等数据技术的飞速发展深刻地改变了人们的生活，互联网服务平台的崛起使全球数十亿用户每天都能产生或浏览海量的信息。随着在线商城（如淘宝、京东等）、社交平台（如 QQ、知乎等）以及网络视频服务平台（如抖音、西瓜视频等）的兴起，使得购物、阅读、观影等各种娱乐活动成为人们日常消费的主要途径，逐渐取代了传统的线下消费方式。据统计，Youtube 用户平均每分钟上传视频 500 小时；Facebook 用户分享消息平均每分钟 1.7MB；用户发送邮件平均每分钟 231MB。互联网用户普遍面临大量信息，当用户难以有效处理和利用这些信息时，就会出现信息过载的问题。因此，如何在海量的数据中迅速且精确地定位用户感兴趣的项目，关键的挑战是如何设计高效的数据检索和推荐系统。推荐系统作为互联网服务平台的核心技术之一，对于促进平台蓬勃发展、推动我国数字经济高质量发展具有极为重要的作用。

推荐系统的基本思想是根据用户的历史交互行为获取用户的兴趣偏好，从大量的候选物品中挑选用户潜在感兴趣的并将其推荐给用户，可以有效减轻信息过载问题。传统的推荐算法主要有基于协同过滤、内容过滤和混合推荐等^[1]，目前已经广泛应用于多种场景。但随着研究的推进以及用户的需求不断变化，现有的推荐算法依旧存在一些问题并极大地限制着推荐系统的性能，比如数据稀疏性、冷启动问题等。数据稀疏性是指少部分用户和项目有交互历史，其余大部分用户和项目之间都是没有数据记录的，可用数据量太少很难挖掘用户的兴趣偏好。冷启动问题是指平台中新用户加入时，没有可用的交互数据，从而无法对用户个性化推荐。近年来，随着互联网应用平台的增多，用户在多个平台上都有交互，因此针对传统推荐算法的缺陷，越来越多的学者关注跨域推荐（Cross-Domain Recommendation, CDR）^[2]。

跨域推荐旨在从其它领域中获取有效的用户偏好特征和物品特征，丰富用户或物品在目标领域中的表示。这种推荐方法可以将多个领域数据相互补充，有效缓解数据稀疏性与冷启动问题，为用户提供更加合理的、个性化的推荐服务。现有的跨域推荐研究主要通过分析用户的行为记录来挖掘项目的潜在特征和关联关系，但绝大多数没有考虑到时间序列信息的重要性。针对用户行为序列进行建模，从用户与项目的交互序列中提取出有价值的时序信息，以此捕捉用户对项目的兴趣偏好，包括用户的短期、长

期、动态等多维度的兴趣表现，有利于提供更加个性化的推荐。因此利用时间信息建模用户顺序行为，进而捕捉用户跨领域兴趣变化的研究显得尤为重要，即为跨域序列推荐（Cross-Domain Sequential Recommendation, CDSR）。跨域序列推荐旨在更好地捕捉用户在不同领域的行为模式，提升推荐的多样性和个性化程度。

近年来，图神经网络（Graph Neural Network, GNN）技术在推荐系统领域中的应用越来越广泛。推荐系统中的许多信息，如用户与物品的互动、用户之间的关系等，均可通过图结构来表达。通过运用图神经网络，能够深入学习用户与物品之间的相互作用，捕捉节点间的复杂联系，从而更准确地获取节点的高维嵌入表示，显著提高推荐质量。因此，本文旨在探讨如何有效地利用图神经网络进行跨领域的序列推荐。

1.2 国内外研究现状

就目前跨领域推荐的研究发现，跨域序列推荐属于跨领域推荐中的一个研究分支，本节将从序列推荐算法、跨域推荐算法和基于图神经网络推荐算法三个方面介绍其研究现状。

1.2.1 序列推荐算法

在日常生活中，大多数消费者行为都会受到个人兴趣和季节性因素的影响。例如，购买完衣服之后，顾客可能会考虑配套购买裤子或搭配的鞋子。同样，由于长期的审美偏好和个人习惯，顾客往往会持续购买特定品牌或款式的服装。这种行为模式的背后，隐藏着对推荐系统极为重要的信息：如何从用户与项目的交互中提炼出有价值的数据，以捕捉到用户对项目的多维度兴趣偏好，包括短期和长期的兴趣，以及兴趣的动态变化。序列推荐算法，通过建模用户行为序列来实现这一目标，旨在从交互序列中挖掘时序信息，进而精准地反映用户的兴趣。序列推荐算法主要可以分为两类：一类是传统序列推荐算法，另一类则利用深度学习技术。通过融合用户的短期和长期兴趣，以及相关的项目信息，提供更加个性化的推荐服务。

传统基于协同过滤的序列推荐模型主要是基于马尔可夫链^[3]，根据用户之前的一个或多个交互记录来计算下一项的转移概率。如 Shani 等人^[4]提出了基于马尔可夫决策过程的推荐方法，通过计算项目之间的转换概率来预测下一个推荐项。Rendle 等人^[5]提出 FP-MC 模型，通过结合主成分分析和马尔可夫链（Markov Chains），建模用户的购物行为。马尔可夫链用于捕捉用户的短期兴趣变化，主成分分析处理用户的总体偏好，从而实现个性化推荐。FP-MC 模型仅考虑用户的正面反馈，为考虑用户的隐式反馈如点击、浏览等行为，其又提出了基于贝叶斯个性化排序的 BPR 模型^[6]。通过构建用户-物品交互的偏好矩阵，并应用矩阵分解（MF）技术学习用户和物品的潜在特征向量，从而预测用户对未交互物品的偏好程度。然而，MF 只能对用户的一般偏好进行建模，而忽视了用户的序列信息。因此，He 等人^[7]使用高阶马尔可夫链，考虑用户更多的历史交互的

依赖关系。后来, Eskandanian 等人^[8]又提出了识别变化点的马尔可夫模型, 关注用户行为序列中用户偏好发生变化的位置, 使用序列感知的非负矩阵分解模型来识别变化点。上述序列推荐方法通过对马尔可夫模型的改进, 提高了推荐的性能。然而, 这些方法仅考虑到用户的短期偏好, 但用户的长期偏好也是需要考虑的, 因此需要组合短期和长期来建模用户的偏好。

近年来, 深度学习在自然语言处理 (NLP) 领域取得了显著的进展, 特别是循环神经网络 (Recurrent Neural Network, RNN) 在序列建模中的优势, 可以捕获用户的长期偏好影响。图1-1展示了序列推荐领域的热点话题, 越来越多基于深度学习的技术和改进结构应用于序列推荐。




图 1-1 序列推荐相关文章的关键词词云^[9]

基于深度学习的序列推荐算法通常是使用一些比较常规的序列建模方法, 例如 RNN、注意力机制、CNN 等^[10], 它们都是通过对用户物品交互序列进行挖掘而得到用户物品的表示。Quadrana 等人^[11]扩展了 RNN 会话建模, 提出层次循环神经网络 (Hierarchical Recurrent Neural Networks), 用其捕捉会话行为序列的时间依赖关系和上下文信息, 其中不同层次的网络负责捕捉不同级别的序列依赖性。Donkers 等人^[12]提出了一种新型门控架构, 在 RNN 上添加门控递归单元 (Gate recurrent Unit, GRU) 对序列的动态信息进行建模, 生成个性化的推荐。为强调用户在当前会话中的偏好, Li 等人^[13]通过在 RNN 上结合注意力机制, 提出基于注意力机制的神经序列推荐模型 (NARM)。NARM 通过混合编码器建模用户的顺序行为, 利用注意力机制捕捉用户在当前会话的偏好, 并将其组合成统一的会话表示。针对现有研究没有明确考虑用户兴趣随时间变化的问题, Liu 等人^[14]又提出了短期注意力/记忆优先级 (Short-Term Attention/Memory Priority, STAMP) 模型, 第一次在基于会话推荐的神经注意模型中同时考虑了用户的长短期记忆, 该模型根据用户会话计算上下文权重, 并结合用户当前的兴趣进行增强。后来, Zhou 等人^[15]考虑到用户兴趣会随着时间的推移而动态变化, 提出了深度兴趣进化网络 (Deep Interest Evolution Network, DIEN), 其主要包含兴趣提取层和兴趣演化层两部分。兴趣提取层采用 GRU 提取行为间的依赖关系, 兴趣演化层通过引入注意力机制嵌入到 GRU 更新门中, 形成 AUGRU 结构, 以更好地捕捉目标物品的兴趣演化过程。

Feng 等人发现用户在同一个会话中的兴趣是相似的,提出了深度会话兴趣网络(Deep Session Interest Network, DSIN)^[16]模型。DSIN 将用户历史行为按时间排序,按照每间隔 30 分钟将其划分为多个会话。然后使用 Transformer 中的多头注意力机制(Multi-head Attention)来提取会话中的兴趣特征,并且采用双向长短记忆网络(Bi-directional Long Short-Term Memory, Bi-LSTM)^[17]学习会话间的演变。Tang 等人^[18]采用卷积神经网络(Convolutional Neural Network, CNN)学习序列特征,并利用隐语义模型(Latent Factor Model, LFM)学习用户特征,捕获用户的一般偏好和顺序模式。虽然这些模型通过序列的表征学习提高了整体推荐性能,但在序列长度有限的情况下,它们仍然存在数据稀疏性的问题。

1.2.2 跨域推荐算法

跨域推荐算法是解决传统单域推荐系统中长期存在的冷启动和数据稀疏性问题的有效方法^[19],通过利用辅助域的信息提高目标领域的推荐性能。传统的跨域推荐可以分为两类,即领域间的知识聚合和源域到目标域的知识转移,研究的方法大多是基于矩阵分解,Berkovsky 等人^[20]使用矩阵分解方式,导入和聚合不同应用领域中用户的评级向量,实现跨域的推荐任务。在此之后,一些研究人员认为,不同领域的用户应该有不同的行为模型,Cao 等人^[21]结合用户及应用程序在多个平台上的数据,通过分离用户的偏好来区分用户对应用程序的固有偏好和平台特有偏好,共同学习共享的跨域特征和领域特定特征。Jiang 等人^[22]通过利用部分重叠用户作为连接域的桥梁,将知识从源域转移到目标域中并以此优化用户在不同平台上的交互行为。

由于传统方法难以学习领域间复杂的用户-项目交互,研究者们引入了基于深度学习的方法,主要分为三种类型:基于转移的方法、基于多任务的方法和基于聚类的方法。基于转移的方法,通过学习领域间的知识将其表示为线性或非线性的映射函数。Elkahky 等人^[23]将用户和项目映射到一个潜在空间,通过引入多视图深度学习模型丰富用户的表示,将不同领域整合成单一的学习模型,以提高所有领域的推荐效果。Man 等人^[24]提出 EMCDDR 模型通过隐向量建模,在域间学习一个映射函数,把域独有和域共享因子明确区分开。基于多任务的方法,通过在神经网络中引入共享连接模块,实现双重知识转移。Hu 等人^[25]提出基于协同过滤的交叉网络 Conet 来实现跨域,利用多个领域的数据同时对多个领域上的模型进行训练,通过模型间的信息交互使得每个领域的推荐性能得到提高。Zhu 等人^[26]提出了 DTCDR 模型,为了提高所有场景的推荐性能,为每个领域构建单独的异构图,并提出了元素级注意力机制以组合不同领域中学习到的用户/项目嵌入特征。基于聚类的方法,通过在统一框架内同时利用单域和跨域信息来学习跨域综合嵌入。Wang 等人^[27]使用相关领域的互补信息来学习完整的项目描述,利用聚类提取跨域的聚类级相关性,通过联合捕获项目及序列信息和集群相关信息,将跨域项目嵌入到统一的空间中。尽管这些研究在众多场合下已被验证为有效,但它们主要针对静态

评分数据设计,无法捕捉到交互数据中存在的顺序依赖关系,不能直接用于跨域序列推荐。因此, Ma 等人^[28]提出了一个并行信息共享网络 π -Net,学习用户特定的表示,并使用门控机制过滤用户的信息,有效地结合时间序列信息,以提高推荐效果。Li 等人^[29]提出了 DASL 模型,采用对偶学习机制,由对偶嵌入和对偶注意力两部分组成,首先构建对偶潜在嵌入并提取两个领域的用户偏好,然后利用对偶注意力机制将提取的潜在嵌入与候选项目进行匹配,以实现跨域序列推荐。

目前,绝大多数跨域推荐算法都是基于深度学习方法实现的,虽然深度学习方法缺乏可解释性,但相比于传统的跨域推荐算法,后者的效果往往表现更好。

1.2.3 基于图神经网络推荐算法

在推荐系统领域,主要的挑战是如何有效地从用户与项目的交互序列和元数据中挖掘出精确的用户和项目的向量表示。推荐系统中的数据通常表现为各种图结构,包括交互图、二分图、异构图和有向图等。鉴于图神经网络在处理这类图形数据上展现出的卓越性能,尤其是它在处理会话推荐、基于社交网络的推荐和序列推荐等任务中扮演着关键角色。近年来,不少学者将其应用于序列推荐中,利用图神经网络建模和捕获用户-物品交互的复杂关系。

2019 年, Wu 等人^[30]首次提出使用图神经网络进行会话推荐,将每条会话序列映射为图结构,利用注意力机制将会话表示为全局偏好和用户当前兴趣。为了捕获物品的转移模式, Qiu 等人^[31]在会话推荐中研究序列中物品的转换模式,提出了 FGNN (Full Graph Neural Network) 模型,通过构建会话图来探究物品转换模式,使用加权注意力学习图中的序列顺序和潜在顺序。由于以往研究只基于当前会话建模用户偏好,但其它会话中也可能包含与当前会话相关的项目转化,因此, Wang 等^[32]提出了全局上下文增强图神经网络 (Global Context Enhanced Graph Neural Networks, GCE-GNN),分别从会话图和全局图中学习项目嵌入。会话图是从当前会话中学习物品嵌入,全局图是在所有会话中建模物品特征来学习全局物品嵌入。

同样地, GNN 也被应用于跨域推荐中,例如, Cheng 等人^[33]针对领域重叠用户问题,构建了一个偏好传播图来进行跨域推荐,其捕捉多跳用户偏好传播,显式地建模跨领域交互并保留结构信息。Liu 等人^[34]在图卷积网络基础上,提出了基于双向迁移图协同过滤网络的跨域推荐模型 (BiTGCF)。该模型通过引入双向特征传播层,利用单领域用户-项目图的高阶连通性。在模型中,同样以重叠用户为桥梁,实现跨领域的双向知识传递。Xi 等人^[35]提出了一种通用的跨域推荐模型图因子分解机 (GFM),利用流行的因子分解机聚合对来自领域的多阶交互进行推荐。该框架不仅有助于使用 GFM 进行跨域推荐任务,并且对现有的各种 GNN 模型都是通用的、可扩展的。Zhu 等人^[36]提出了基于图神经网络和注意力的双目标跨域推荐模型 (GA-DTCDR),利用两个领域的评论信息和项目内容信息构建两个独立的二分图,并使用 Node2vec 算法^[37]在图上学习以获得

用户和项目的嵌入表示向量，然后使用元素级注意力机制结合两个域学习的用户嵌入。Cui 等人^[38]提出双目标跨域推荐，将所有领域构建了一个共享的异构图，并使用循环注意力为节点建模异构邻居，通过聚合多个域的用户和物品邻居，在领域间传递信息，以缓解稀疏性问题。

上述基于 GNN 的跨域推荐方法忽略了用户的动态时序信息，因此，Ren 等人^[39]提出了一种跨域顺序推荐的混合信息流网络（MIFN），利用跨域图卷积机制传播知识图谱中的项目信息，通过引入行为传递单元和知识传递单元同时考虑信息流和知识流，MIFN 能够根据用户当前偏好来决定何时使用跨域信息以丰富序列表示。Guo 等人^[40]设计了一个基于注意机制的领域感知卷积网络 DA-GCN 来学习节点表征，该方法通过知识转移将两个领域连接起来，但未考虑项目之间的时间间隔信息。因此在 2022 年提出了 TiDA-GCN 模型^[41]，在 DA-GCN 模型的基础上将时间间隔纳入消息传递机制中，并加入了一个自注意力模块学习项目的序列表示，以增强项目的表示。Zheng 等人^[42]为保留单域偏好又整合跨域影响，通过构建双重动态图（即局部图和全局图）来捕获领域内和领域间的顺序变化，再使用混合度量增强用户和项目的表示，以捕获用户动态信息，缓解数据稀疏性问题。

目前跨领域序列推荐研究中，大多独立于每个领域捕捉用户的偏好，忽略了不同领域序列之间的项目转移模式。由于目标域和源域中的某些项交互次数有限，因此数据稀疏性问题仍然存在。并且简单地传递有偏向的单域偏好很难精确地描述跨域用户的偏好，容易导致推荐结果出现不稳定以及负迁移等问题。

1.3 本文的主要创新点

随着数字化时代的到来，应用平台数量的急剧增加使用户的在线行为变得更加多元化。从社交媒体、电子商务到在线教育等，人们在日常生活的各个领域内寻找信息、进行交互以及完成交易。用户的跨领域行为激增，为推荐系统带来了新的挑战和机遇。传统的推荐系统往往局限于单一领域，例如仅在电商平台上推荐商品或在社交媒体上推荐相似内容，难以全面理解和满足用户的复杂需求。跨域序列推荐通过综合分析用户在不同领域内的行为序列，发现用户的跨域行为模式和偏好，从而为用户提供更加精准和个性化的推荐。然而，现有的跨域序列推荐方法仍然存在一些不足，如忽略了领域序列项目转换模式、忽视项目时间间隔信息、未考虑领域节点的重要性等。基于这些问题，本文利用图神经网络的方法，将用户在不同领域的交互数据分别从单域和跨域两个方面来学习用户和项目之间的交互，以捕捉数据节点间复杂的关联关系。

本文的主要创新点如下：

(1) 提出了基于时间感知的图神经网络跨域推荐（Time-Aware Graph Neural Network for Cross-Domain Recommendation, TAGNN）模型，针对跨域序列推荐未考虑领域项目转换模式以及交互时间间隔问题。首先将用户在不同领域的交互序列按时间顺序构建

跨域序列,并分别构造用户序列图和跨域全局图。用户序列图为有向图,采用门控图神经网络(GGNN)作为图编码器选择性地聚合、更新节点嵌入,提取用户领域内动态序列信息。跨域全局图根据用户在不同领域的交互序列,将每个用户节点链接到与其交互的项目节点,来自不同领域的项目节点通过用户节点进行关联,从而实现知识在不同序列和领域之间传递,利用图卷积网络学习跨域全局图中领域间的项目协作信息。其次,为考虑项目时间间隔信息并增强序列的表征学习,提出了时间间隔注意力编码器(TiAttEncoder),将时间间隔信息融入注意力模块中学习项目的交互特征。然后,为权衡跨域序列中项目对目标域的重要性,提出了一种基于对比学习的辅助任务。具体的,利用softmax函数计算跨域序列中源域项目对目标域的相关性,相关性小于0.5的项目用掩码替换,经过替换后得到对比序列,然后将目标域序列与对比序列进行对比学习,通过最大化域内和跨域序列来增强它们之间的相关性。最后,联合域内推荐任务、跨域推荐任务以及辅助任务对模型进行优化。

(2) 针对基于图卷积的跨域推荐忽略了领域节点重要程度的问题,提出了基于注意力和时间感知的图神经网络跨域推荐(Attention and Time-Aware Graph Neural Network for Cross-Domain Recommendation, ATAGNN)模型。在跨域全局图中,为区分不同领域项目对用户偏好的影响,提出了层级注意力图卷积网络(Graph Convolutional Networks with Hierarchical Attention, HAGCN),通过层级注意力从节点级和领域级自动区分领域间项目节点的重要性,以学习项目嵌入。为更好地结合跨域信息,将用户序列图和跨域全局图学习到的图嵌入进行聚合,并将得到的聚合嵌入和跨域图嵌入通过序列编码器得到目标域和跨域中的用户顺序偏好。

(3) 本文在亚马逊的两组数据集 Movie-Book、Food-Kitchen 上开展了大量实验,首先与传统推荐模型、序列推荐模型以及跨域推荐模型进行了实验对比,实验结果表明,本文提出的 TAGNN 模型和 ATAGNN 模型与主流基线模型相比具有明显的优势,在 HR 和 NDCG 等评价指标上都有了一定的提升。同时对模型进行了消融实验对比,证明了模型结构的合理性和有效性。

(4) 开发了一个基于 ATAGNN 模型的电影图书推荐系统,该系统实现了用户对电影、图书网站的基本需求,包括搜索、推荐、评分等功能,且能够根据用户在两个领域的历史交互数据,为用户推荐感兴趣的电影或图书,并可依据用户的反馈信息进行调整和优化,从而不断地提升推荐效果。

1.4 本文的组织架构

本文共分为六个章节,结构安排如下:

第1章:绪论。首先介绍了本文的研究背景及意义。接着分别从序列推荐、跨域推荐以及基于图神经网络的推荐等三个方面给出了国内外的研究现状。然后给出了本文的主要创新点,即所提出的两种基于图的模型和它们对于跨域序列推荐任务的先进性。最

后阐述了论文的组织架构和各章节的主要内容。

第 2 章：相关理论与技术。分别介绍了跨域推荐中的相关概念，包括域的定义、常见的跨域推荐方法分类、注意力机制、图神经网络技术（图卷积网络、门控图神经网络、图注意力网络）以及对比学习等，为本文的推荐方法的提出提供了理论依据。

第 3 章：提出了基于时间感知的图神经网络跨域推荐模型（TAGNN）。首先通过分析现有跨域序列推荐模型的不足，为本章创新模型提供研究思路。然后对 TAGNN 模型架构与功能进行详细说明。最后在两组场景数据集上进行验证模型性能的实验，包括整体模型性能的对比、四种消融实验以及超参数学习的实验。

第 4 章：提出了基于注意力和时间感知的图神经网络跨域推荐模型（ATAGNN）。阐述了层级注意力图卷积网络（HAGCN）、消息传递、聚合的详细过程，以及图嵌入聚合的过程，然后给出模型整体架构，通过消融实验和与基线模型的对比实验，证明了模型结构的合理性与优越性。

第 5 章：开发了基于 ATAGNN 模型的跨领域推荐系统。从需求分析、系统架构设计包括系统整体架构、功能模块设计以及数据库设计四个方面对推荐系统进行了详细的介绍，并对系统运行界面进行展示，最后通过功能测试与性能测试，证明了系统的可靠性与可用性。

第 6 章：总结与展望。对本文所提出的改进模型进行总结，分析其存在的优势和不足，并为后续工作的改进提供了一些新的研究思路。

论文整体结构如图1-2所示。




图 1-2 论文结构图

第2章 相关理论与技术

本章主要介绍了跨域推荐的相关概念、注意力机制、图神经网络相关技术（即图卷积网络、门控图神经网络、图注意网络）以及对比学习。

2.1 跨域推荐概念

跨域推荐（CDR）是一种解决信息过载问题的技术，通过利用用户在一个领域（域A）的历史行为数据，为用户在另一个不同的领域（域B）推荐相关物品。这种技术的关键挑战在于如何有效地迁移和利用跨领域的知识，以提高推荐的准确性和多样性。一般而言，A域是信息较为丰富的源域或者辅助域，B域是信息较为稀疏的目标域，借助用户在不同领域的兴趣和偏好进行统一分析和建模，从而提高推荐的准确性。跨域推荐系统中，根据不同的分类方法，存在多种推荐策略。接下来，将简要介绍这些不同的推荐方法。

2.1.1 域的定义

在跨域推荐中，域（domain）的概念也是比较重要的。其用于描述不同推荐对象的关联性和差异性。一个域通常指的是不同的属性、特征或属性值的数据集合^[43]。跨域推荐中，需要定义每个域的特征或数据类型，以便系统能有效地对不同域之间的数据进行比较和推荐^[44]。在实际应用中，域可以是电商平台、应用程序、社交网络等。不同域之间的推荐对象也可能不同，如短视频、新闻、电影、图书等。与此同时，不同域之间的推荐对象也可能存在相关性，例如用户在观看电影时可能会受到其阅读图书的影响。因此，在设计推荐算法时，首先应该考虑用户在不同领域的重叠情况，因为不同领域用户的重叠信息对于领域间的信息迁移和共享起着至关重要的作用。Zhu等人^[45]从三个角度定义域，即内容级相关性、用户级相关性和项目级相关性。

内容级相关性：在不同领域中的用户/项目存在相同的元数据特征，如用户关键字、标签属性以及项目的详细信息等。例如亚马逊音乐^①和奈飞网站^②业务较为相似，虽然没有很多相同的用户和项目，但用户和项目的属性是类似的。

用户级相关性：在两个或多个领域中，存在很多相同的用户但不同级别的项目。相同类型的项目但具有不同的属性值，例如散文诗集和科幻小说，或者是不同类型的项目如音乐和图书。

项目级别相关性：在两个或多个域中，有很多相同的项目（如电影）和不同的用户，

^①<https://www.amazon.com/music>

^②<https://www.netflix.com/>

例如，MovieLens[®]和奈飞网站有很多相同的电影。

2.1.2 跨域推荐方法

跨域推荐主要分为单目标推荐、多域推荐、双目标推荐以及多目标推荐等。这些方法之间的主要区别是域的规模、重叠情况和改进目标。

单目标跨域推荐（Single-Target Cross Domain Recommendation），是 CDR 领域的传统推荐场景，现有的 CDR 方法大多针对这一场景，其主要目标是利用源域的信息提升目标域的推荐准确率。单目标跨域推荐可以进行特征层面的参数共享，也可以进行用户/项目的嵌入共享，即直接把源域的嵌入用到目标域上，或者学习某种精确的映射关系^[46]。如图2-1所示，其中共同实体可以是重叠用户、重叠项目、或者共同属性等内容。




图 2-1 单目标跨域推荐

多域推荐（Multi-Domain Recommendation, MDR）是在单目标跨域推荐的基础上实现的。MDR 聚合来自多个域的信息，将聚合域上的项目推荐给相应的用户，如图2-2所示。




图 2-2 多域推荐

双目标跨域推荐（Dual-Target Cross Domain Recommendation），旨在同时提高两个领域的推荐效果，两个域既可以是目标域也可以是源域，两个领域的信息相辅相成，其类似于多任务学习，如图2-3所示。

[®]<https://movielens.org/>




图 2-3 双目标跨域推荐

多目标跨域推荐（Multi-Target Cross Domain Recommendation），受双目标跨域推荐启发，在多目标跨域推荐场景中，利用更多领域的信息同时提高多个领域的推荐准确率。随着领域的增加，尤其是稀疏域，可能会出现负转移问题，即某些领域中的推荐性能会下降，如图2-4所示。




图 2-4 多目标跨域推荐

2.2 注意力机制

深度学习中，注意力机制（Attention Mechanism）是一种模仿人类视觉和认知系统的技术，它使得神经网络在处理输入数据时聚焦于相关的部分。引入注意力机制使得神经网络能够自动学习并有选择性地关注输入中的重要信息，从而提升模型的性能和泛化能力。注意力机制的核心优势在于其能通过学习为序列中的不同部分分配适当的权重，从而让模型更精准地捕捉项目间的相关性。近年来，注意力机制已被广泛应用于许多领域中，在推荐系统应用中也发挥了重要的作用。

注意力机制可被理解为从大量信息中筛选出少量重要信息，并将注意力聚焦在这些重要信息上。计算权重的分布为聚焦注意力的过程，其中权重的大小表示信息的重要程度，本质上是一个自动加权求和，权重越大的数值会获得更多的注意，从而反映了信息的相对重要性。一个简单的注意力机制示意图如图2-5所示。

例如，序列 $\{x_1, x_2, \dots, x_n, \dots, x_N\} \in \mathbb{R}^{d_k \times N}$ 表示输入的信息，注意力机制计算过程如下。首先给定一个查询向量 $q \in \mathbb{R}^{d_k}$ ，使用注意力变量 $n \in [1, N]$ 表示被索引信息的位




图 2-5 简单注意力机制示意图

置。给定 q 和 x ，选择第 n 个输入向量的概率 α_n 为：

$$\alpha_n = \text{softmax}(s(x_n, q)) = \frac{\exp(s(x_n, q))}{\sum_{j=1}^N \exp(s(x_j, q))} \quad (2-1)$$

其中 α_n 为注意力分布，表示给定相关查询 q 时，第 n 个向量受关注的程度。 $s(x_n, q)$ 为注意力评分函数，常用的主要有向量点积、缩放点积、MLP 网络等，如下：

(1) 点积：

$$s(x_n, q) = x_n q \quad (2-2)$$

(2) 缩放点积：

$$s(x_n, q) = \frac{x_n q}{\sqrt{d_k}} \quad (2-3)$$

(3) MLP 网络：

$$s(x_n, q) = \text{MLP}(x_n, q) \quad (2-4)$$

然后根据注意力分布计算输入的加权平均，最终注意力得分计算如下：

$$\alpha_{tt}(X, q) = \sum_{n=1}^N \alpha_n x_n \quad (2-5)$$

早期，在图像领域中，注意力机制取得了显著的效果，这促使研究者们开始在不同领域中应用注意力机制。2017 年 Google 团队提出 Transformer^[47]将自注意力机制（Self-Attention）应用到了机器翻译的任务中。利用自注意机制实现序列信息的编码与解码，通过这种方式完成了特征提取工作。这一技术的应用使得自注意力机制在自然语言处理领域得到了快速的发展和应用。

编码器和解码器是 Transformer 模型的两个重要组成部分。其通过缩放点积注意力机制（Scaled Dot-Product Attention）和多头注意力机制（Multi-Head Attention）实现特征提取，其流程如图2-6所示。




图 2-6 Transformer 模型的注意力机制

输入向量 $X = (x_1, x_2, \dots, x_n)$ 分别与初始化的三个向量矩阵 W^Q 、 W^K 、 W^V 相乘，获得 Q 、 K 、 V ，其计算如公式2-6所示。

$$\begin{aligned} Q &= W^Q X \\ K &= W^K X \\ V &= W^V X \end{aligned} \quad (2-6)$$

通过点积的方式计算 Q 和 K 两个向量的相关性，从而得到注意力的值 α 。为了避免结果值过大，将 α 按照 W^K 矩阵第一维度的系数比例进行缩小，然后将得到的结果归一化，与矩阵 V 做加权求和得到自注意力的表示。自注意力机制计算流程如图2-7所示，计算过程如公式2-7所示。

$$attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2-7)$$

多头注意力机制是一种并行地进行自注意力运算的方法，其中每次自注意力运算被称为一个头 (head)，并且每个 head 之间的参数是独立、不共享的，将得到的多个注意力向量进行拼接，得到最终的结果。如公式2-8和公式2-9所示。

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_h)W^o \quad (2-8)$$

$$head_i = Attention(QW_i^Q KW_i^K VW_i^V) \quad (2-9)$$

其中 h 表示多头注意力的 head 个数。




图 2-7 自注意力机制内部计算图

为了使 Transformer 模型能更有效地处理序列信息，又在其中引入相对位置编码模块，使其能够理解序列中不同位置之间的关系。具体操作是使用余弦函数和正弦函数编码位置信息。这样的编码方式允许模型在处理序列时，考虑序列中不同位置之间的相对距离和顺序关系。计算公式如2-10、2-11所示。

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2-10)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d_{model}}}\right) \quad (2-11)$$

2.3 图神经网络技术

近年来，神经网络的兴起与应用成功地推动了模式识别和数据挖掘的研究。曾经依赖手工提取特征的机器学习任务（如目标检测、机器翻译和语音识别），如今已经被各种端到端的深度学习技术（例如卷积神经网络 CNN、长短期记忆 LSTM 和自动编码）所改变。尽管传统的深度学习方法在欧氏数据的特征提取方面取得了巨大的成功，但现实生活中许多场景的数据是非欧氏结构的，例如图结构、社交网络、知识图谱等^[48]。传统的深度学习方法无法很好地处理非欧式空间数据。例如，基于图的推荐系统能够利用用户和物品之间的交互来做出非常准确的推荐，但图的复杂性使得现有的深度学习算法在处理图结构数据时面临着巨大的挑战。因为图是不规则的，每个图都有一个大小可变的无序节点，图中的每个节点都有不同数量的相邻节点，导致一些操作在图像上很容易计算，但不能直接用于图结构上。

为解决图结构的问题，图神经网络应运而生。图神经网络是一种特殊的深度学习模型，用于处理基于图结构的数据，如推荐系统中的用户行为数据、社交网络和生物信息学中的分子结构数据等。其基本思想是通过训练可学习的参数，利用节点的邻居信息更新图中每个节点的表示，从而完成基于图结构数据的复杂任务^[49]，如节点分类、图生成以及链路预测等。图是由节点和边组成，其中节点表示系统中的元素，而边表示节点之

间的关系。图神经网络的本质是通过一系列层次的特征提取来对图数据进行处理和建模。特征提取通过不断地将节点本身特征和与其相邻节点的信息进行聚合和融合，最终得到新的节点特征表示。

推荐系统中常用的图神经网络有图卷积神经网络 (Graph Convolutional Networks, GCN)^[50]、图注意力网络 (Graph Attention Networks, GAT)^[51]和门控图神经网络 (Gated Graph Neural Networks, GGNN)^[52]等。

2.3.1 图卷积神经网络

图卷积神经网络 (GCN) 与卷积神经网络类似，都是用于特征提取，但 GCN 的输入是图数据。给定图结构 $G = (V, E)$ ，其中 V 表示节点， E 表示边，图卷积网络将原始图结构数据 G 映射到特征空间中。假设有 N 个节点，各个节点之间的关系会形成一个 $N \times N$ 维的邻接矩阵 A ，第 $l+1$ 层的输出为 $H^{(l+1)}$ ， σ 为非线性激活函数，如 $ReLU$ 或 $softmax$ 等。GCN 的卷积操作如公式2-12所示。

$$H^{(l+1)} = \sigma(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)}) \quad (2-12)$$

其中 $\tilde{A} = A + I$ ， I 为单位矩阵。 $\tilde{D}$ 为 $\tilde{A}$ 的度矩阵，计算公式为 $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$ 。GCN 利用多跳传播机制，有效地共享卷积局部参数，并将多跳内的知识信息聚集到节点的嵌入表示中。GCN 在其发展过程中经历了两个阶段：频域和空间。在频域阶段，GCN 主要集中在频域的理论基础和算法设计上，着重于对图进行卷积操作，并探索如何有效地在频域中表示和处理图数据。而在空间阶段，GCN 研究的重点逐渐转移到空间结构的建模和局部连接模式的挖掘，更加关注节点之间的直接相互作用，以捕获图数据中的局部结构和全局信息。目前，基于空间的图卷积网络因其优越的性能在真实的应用中被广泛使用，如下面要介绍的轻量级图卷积网络 LightGCN。

图卷积神经网络利用邻居节点的特征加权汇聚，生成每个节点的新特征表示，可视为基于邻居信息的卷积操作，通常由一个图卷积、线性层以及非线性激活组成。GCN 邻域聚合如公式2-13所示。

$$e_u^{(k+1)} = AGG(e_u^{(k)}, \{e_i^{(k)} : i \in N_u\}) \quad (2-13)$$

AGG 表示聚合函数，一般包含了特征变换矩阵 W 和非线性激活函数 $\sigma(\cdot)$ ，其考虑了目标节点及其邻居节点的第 k 层，虽然聚合函数在具有语义输入特征的节点上表现良好，但大多数推荐任务只使用到用户和项目标识，没有其它的属性，因此它对于基于协同过滤的推荐模型来说可能会带来负作用。LightGCN 是一种简化的图卷积神经网络模型，其设计目的是为了解决传统的基于邻居聚合的图卷积神经网络 (如 GCN) 中存在的一些问题，如计算复杂度高、层次过多导致信息丢失等。通过简化模型结构和减少参数量，采用了简单的加权和聚合器，摒弃图卷积神经网络中的特征变换和非线性激活函数，

在同一推荐场景下取得了比传统模型更好的性能表现。具体如公式2-14、公式2-15所示。

$$e_u^{(k+1)} = \sum_{i \in N_u} \frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}} e_i^{(k)} \quad (2-14)$$

$$e_i^{(k+1)} = \sum_{u \in N_i} \frac{1}{\sqrt{|N_i|}\sqrt{|N_u|}} e_u^{(k)} \quad (2-15)$$

其中, N_u 表示用户 u 交互的项目集合, $|N_u|$ 为项目数量, N_i 表示与项目 i 交互的用户集, $|N_i|$ 为用户数量。对称化归一项 $\frac{1}{\sqrt{|N_u|}\sqrt{|N_i|}}$ 可以避免在进行图卷积运算时增加嵌入的规模。

2.3.2 门控图神经网络

GGNN 是一种图神经网络模型,它在节点级别进行信息聚合。与 GCN 不同, GGNN 不会在所有节点上应用相同的线性变换,而是通过可学习的非线性门控机制来更新每个节点的状态。门控机制可以控制每个节点从其相邻节点接收的信息量。门控图神经网络通过反复地应用门控单元来更新每个节点的状态,直至收敛。在时间步 t 内,节点的状态表示为向量 $h_i^{(t)}$, 其中 i 表示节点的索引。门控图神经网络的基本思想是对于每个节点,首先将其与相邻节点的状态进行聚合,然后应用门控单元来控制节点的信息流动,从而更新节点的状态。门控机制的输出可以认为是一个消息传递函数,用于控制节点之间的信息流动。具体而言,对于每个节点 i ,其状态的更新方式,即通过聚合相邻节点的状态信息,并应用门控机制来更新节点的状态,如公式2-16所示。

$$h_v^t = f(h_v^{t-1}, \sum_{u \in N(v)} W_e^{(t)} \cdot h_u^{t-1}) \quad (2-16)$$

其中, $W_e^{(t)}$ 是可学习的边特征矩阵, $N(v)$ 表示节点 v 的邻居节点集合, f 是门控机制,通常是一个门控循环单元 (GRU) 或者长短期记忆网络 (LSTM),用来更新节点的状态。门控图神经网络结合了门控单元和可学习参数来处理图数据,解决了图卷积网络无法学习节点前后相关性的缺陷。

2.3.3 图注意力网络

图注意力网络 (GAT) 将注意力机制引入到基于空间域的图神经网络中,其解决了图卷积网络的几个缺陷,即 GCN 进行图卷积操作时需要构建拉普拉斯矩阵,而拉普拉斯矩阵需要知道整个图结构;其次因 GCN 对于同一个节点的不同邻居在卷积时使用相同的权重,而 GAT 为图结构中重要信息提供注意力和焦点,而不是关注整个图数据。在图卷积操作过程中,仅需要一阶邻居节点的信息并通过注意力机制针对不同邻居节点学习不同的权重,利用邻居对节点的影响计算所有节点的隐藏状态。

为了获得足够的表达能力, 将输入特征转换为更高阶的特征, 初始对所有节点训练一个共享权重矩阵 $W \in \mathbb{R}^{F' \times F}$, 其表示输入的 F 个特征与输出的 F' 个特征之间的映射关系, h 表示输入的一组节点特征, $\vec{h} \in \mathbb{R}^{F'}$ 。

$$e_{ij} = a(W\vec{h}_i, W\vec{h}_j) \quad (2-17)$$

$$\alpha_{ij} = \text{softmax}_j(e_{ij}) = \frac{\exp(e_{ij})}{\sum_{k \in N_i} \exp(e_{ik})} \quad (2-18)$$

图2-8左图采用注意力机制计算节点间的权重信息, 并使用 LeakyReLU 激活函数。其计算过程如公式2-19。

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\vec{\alpha}^T [W\vec{h}_i \parallel W\vec{h}_j]))}{\sum_{k \in N_i} \exp(\text{LeakyReLU}(\vec{\alpha}^T [W\vec{h}_i \parallel W\vec{h}_k]))} \quad (2-19)$$




图 2-8 图注意力网络^[52]

其中, $\cdot^T$ 表示转置, $\parallel$ 为连接操作。节点 i 的隐藏状态计算如公式2-20。

$$\vec{h}'_i = \sigma(\sum_{j \in N_i} \alpha_{ij} W\vec{h}_j) \quad (2-20)$$

为了使自注意力能够稳定地表示节点, 引入了多头注意力机制来提高模型的表征能力。对于中间层输出特征, 使用 k 个 W 计算自注意力, 然后将注意力头得到的结果拼接得到输出向量, 最后对各个注意力头的输出向量求平均。计算过程如图2-8右图所示, 计算公式如2-21、2-22。

$$\vec{h}'_i = \prod_{k=1}^K \sigma(\sum_{j \in N_i} \alpha_{ij}^k W^k \vec{h}_j) \quad (2-21)$$

$$\vec{h}'_i = \sigma(\frac{1}{K} \sum_{k=1}^K \sum_{j \in N_i} \alpha_{ij}^k W^k \vec{h}_j) \quad (2-22)$$

α_{ij}^k 为第 k 个注意力机制的归一化注意系数。

2.4 对比学习

自监督学习在计算机视觉和自然语言处理等领域被广泛应用，其从大量数据中学习同类数据的相同特性，并将其编码为高级表征，再根据不同任务进行微调。主要分为两类：生成式学习和对比式学习，如图2-9所示。





图 2-9 自监督学习分类

对比学习（Contrastive Learning）主要目标是通过学习相似性和差异性来提高模型性能。在对比学习中，模型被训练去区分数据中的正例对（相似样本）和负例对（不相似样本），通过最大化正例对的相似性和最小化负例对的相似性来学习特征的表示。具体来说，对于给定一对样本，将它们的表示空间中的距离缩小，也就是使给定的点到正样本的距离尽可能小，到负样本的距离尽可能大。推荐系统可以为用户提供个性化推荐，然而有时推荐的效果并不是那么准确，主要原因可能如下：

1. 数据分布存在偏差：在理想情况下，为确保数据无偏，所有用户应与所有项目有交互。但实际上，推荐系统仅能向用户展示有限的项目集合，从而导致未曝光项目与用户间的实际交互情况未知，进而产生数据偏差。推荐系统通常偏向于推荐那些已经被频繁曝光的流行项目，忽略了挖掘用户个性化兴趣偏好的重要性，导致推荐效果与用户的真实需求存在偏差。

2. 噪音干扰：推荐系统不仅存在数据稀疏性问题，同时存在用户误点、错点等现象。使用对比学习对数据进行增强和扩增，能在一定程度上缓解上述问题，提高模型的表征能力，更好地适配下游任务。对比学习的主要思想是学习一个编码器，将每一个实例如用户、项目等看作一个类，对同类数据进行相似的编码，并使不同类的数据编码结果尽可能不同。

通常，将相同实例的两个变体视为正对，不同实例的变体视为负对。通过最大化正对之间的一致性，同时最小化负对之间的一致性，可以获得用于推荐的区分表示，如图2-10所示。

图 2-10 对比学习^[53]

$$f_{\theta}^* = \arg \min_{f_{\theta}, g_{\phi_s}} L_{ssl}(g_{\phi_s}(f_{\theta}(\tilde{D}_1), f_{\theta}(\tilde{D}_2))) \quad (2-23)$$

图神经网络的对比学习中，使用局部-局部对比^[53]，以最大化用户或者项目节点表示之间的交互信息：

$$f_{\theta}^* = \arg \min_{f_{\theta}, g_{\phi_s}} L_{MI}(g_{\phi_s}(\tilde{h}_i, \tilde{h}_j)) \quad (2-24)$$

在序列推荐中，经常运用全局对比^[53]，将序列作为用户的全局视图：

$$f_{\theta}^* = \arg \min_{f_{\theta}, g_{\phi_s}} L_{MI}(g_{\phi_s}(Agg(f_{\theta}(\tilde{S}_i), Agg(f_{\theta}(\tilde{S}_j)))))) \quad (2-25)$$

其中 $\tilde{S}_i, \tilde{S}_j$ 表示两个增强的序列， Agg 表示合成序列的聚合函数。

2.5 本章小结

本章主要介绍了与本文工作相关的跨域推荐方面的理论和技术。首先对跨域的“域”的定义进行简单介绍，并介绍跨域推荐中常见的方法。然后介绍了涉及到的相关技术，其中包含注意力机制、图神经网络模型以及对比学习等，给出了其相关的重要定义、算法流程以及其优缺点，为后继所研究的跨域序列推荐模型提供了理论基础。

第3章 基于时间感知的图神经网络跨域推荐模型

图神经网络（GNN）因在捕捉图结构数据特征方面的强大能力，已经成为处理图形域信息的主流方法。GNN 通过在图中节点间有效地传递信息，能够深入挖掘节点和边之间的复杂关系。用户在不同领域上的交互形成了丰富的行为序列，这些行为序列构成了一个序列图，其中包含了用户在不同时间点的交互历史和跨域行为模式。GNN 可以通过学习这些图的结构特征来理解用户的兴趣和偏好，进而提供个性化推荐。

3.1 引言

图神经网络与传统的深度学习模型有着显著的区别，它具有处理非欧式数据的能力，如社交网络、信息网络等。GNN 通过聚合从相邻节点获得的信息来更新节点状态，并与相邻节点进行交互。其主要思想是利用神经网络的迭代聚合，从局部图邻域中获取特征信息，同时通过转换和聚合传播节点信息。因此，图神经网络在节点信息和拓扑结构的结合中展现了强大的表示学习潜力。

现有的跨域序列推荐研究中有两个重要问题需要解决：一方面，目前的跨域序列推荐算法大多只针对序列内项目建模，忽略了不同领域序列之间的项目转换模式，即用户在一个域中的交互可能会影响在其它领域中的下一次交互。简单来说，用户的偏好可以通过其在多个领域的行为来反映，如图3-1，用户在一段时间内在电影域和图书域中交替进行了一些交互。从中很容易观察到，用户下一部电影《哈利波特》的选择不仅取决于其之前在电影域内对悬疑奇幻电影的兴趣，也取决于图书域对《哈利波特》原著的阅读经历，在单域推荐中很难精准捕捉到用户这样的领域偏好。另一方面，现有的跨域序



图 3-1 用户交互示例图

列推荐在很大程度上未考虑项目间的时间间隔信息,而时间信息是捕捉用户意图变化的重要信号。例如,9月份用户在图书领域显示更喜欢浪漫书籍,并且这种动态兴趣也影响其在接下来的一个月在电影领域的兴趣。

为解决第一个问题,可将用户序列数据引入到图结构中,利用图神经网络学习节点信息,捕捉领域内和跨领域节点状态的演变过程,能更好地感知节点在序列中的上下文,提高对动态关系的建模能力,在表征学习中同时捕获序列内和序列间的项目关系,从而提升模型的表现。第二个要解决的问题是如何考虑时间间隔信息。在实际中,不同时间间隔的项目可能对用户有不同的吸引力。例如,用户可能在短时间内频繁购买日常消费品,而在较长的时间间隔内购买电子产品。因此,项目之间的时间间隔提供了区分项目类型和特征的重要信号。为了考虑项目对用户的不同吸引力,本章引入项目的时间间隔信息,利用项目之间的相对时间间隔,进一步增强项目的表示学习。为了学习序列级别的交互特征,引入了注意力机制聚合所有的项目,从而得到更加准确的用户特征表示。此外,为了更好地理解跨领域序列中不同领域之间的相关性,提出了基于对比学习的辅助任务,以增强跨领域序列的表征。

综上所述,本章设计了一种新颖的基于时间感知的图神经网络跨域推荐模型(Time-Aware Graph Neural Network for Cross-Domain Recommendation, TAGNN)。图神经网络的引入使得推荐系统能够更好地建模用户和项目之间的复杂关系。通过将用户和项目表示为图中的节点,并通过边来表示它们之间的关联,GNN能够有效地捕捉到跨域信息,从而提高推荐的准确性。同时,引入时间间隔信息能确保模型考虑到用户行为随时间演变的过程,为模型提供了时间上的相关性和适应性。

3.2 模型构建

3.2.1 模型结构

TAGNN的关键思想是使用图神经网络分别学习用户域内序列图和跨域全局图,学习域内项目表示和域间用户偏好,结合序列内的动态时序信息和跨域全局中的静态协作信息。从域间用户偏好的角度,捕捉用户偏好的补充信息,以提高用户在目标域的推荐性能。

图3-2为整体模型,TAGNN根据用户在不同领域的交互序列数据,分别构建用户在领域内的序列图和跨域全局图。采用门控图神经网络(GGNN)作为单域序列图的编码器来更新项目嵌入,捕捉用户-物品间复杂的交互模式和依赖关系。跨域全局图利用图卷积网络学习来自不同领域的项目之间的协作信息,在图的构造中,不同领域的项目节点可以通过用户节点进行关联,从而实现知识在不同序列和领域之间的传递,有助于生成更准确的推荐。用户序列图包含用户在单个领域内的行为序列的动态信息,跨域全局图包含跨域序列的静态协同信息。然后将用户序列图嵌入和跨域全局图嵌入分别输入到时间间隔编码器 TiAttEncoder 中,以增强项目的表征得到用户顺序偏好。此外,本章




图 3-2 TAGNN 整体结构图

引入两种不同的序列训练目标来获取用户的单域和跨域表示，并通过辅助任务最大化单域和跨域用户表示的交互信息来联合训练模型，以增强域内序列和跨域序列之间的相关性。

3.2.2 输入与嵌入层

跨域序列推荐通过用户在不同领域的历史交互来推荐下一个项目。考虑两个不同的领域 X 域和 Y 域， $U = \{u_1, u_2, u_3, \dots, u_k\}$ 表示 X 域和 Y 域中的重叠用户集合，其中 k 表示重叠用户数目。输入 $S_X = \{x_1, x_2, \dots, x_i, \dots\}$ ， $S_Y = \{y_1, y_2, \dots, y_j, \dots\}$ 表示用户在不同领域中的交互序列， $S = \{x_1, y_1, y_2, \dots, x_n, y_m\}$ 表示将两个域的交互序列按照时间顺序排列的跨域序列。TAGNN 的任务是根据用户在不同领域中过去的行为序列推荐下一项。 X 域和 Y 域中的候选项被推荐概率为：

$$\begin{aligned} P(x_{i+1} | S_X, S_Y) &\sim f_X(S_X, S_Y) \\ P(y_{j+1} | S_Y, S_X) &\sim f_Y(S_Y, S_X) \end{aligned} \quad (3-1)$$

其中 $P(x_{i+1} | S_X, S_Y)$ 和 $P(y_{j+1} | S_Y, S_X)$ 分别表示在给定序列 S_X ， S_Y 时，推荐 X 域和 Y 域中下一项 x_{i+1} ， y_{j+1} 的概率。 $f_X(S_X, S_Y)$ 和 $f_Y(S_Y, S_X)$ 表示用于估计的学习函数。

嵌入层主要作用是得到所有输入项目的初始嵌入向量。在嵌入映射阶段，为了获得单域和跨域交互序列的初始项表示，构造三个参数矩阵作为嵌入初始化： $E^X \in \mathbb{R}^{|X| \times d}$ 、 $E^Y \in \mathbb{R}^{|Y| \times d}$ 和 $E^G \in \mathbb{R}^{(|X|+|Y|) \times d}$ ，其中 d 是嵌入的维度。此外，为了识别序列的顺序信息，设置位置嵌入矩阵 $P \in \mathbb{R}^{l \times d}$ ， l 是交互序列的最大长度。为进一步增强项目表征学习，在序列中加入时间间隔信息。具体而言，给定一个交互序列 $[t_1, t_2, \dots, t_l]$ ，用 $t_{pq} = |t_p - t_q|$ 表示项目 p 和项目 q 之间的时间间隔，得到时间间隔矩阵 $T \in \mathbb{R}^{l \times l}$ 。

$$T = \begin{bmatrix} t_{11} & t_{12} & \cdots & t_{1l} \\ t_{21} & t_{22} & \cdots & t_{2l} \\ \vdots & \vdots & \vdots & \vdots \\ t_{l1} & t_{l2} & \cdots & t_{ll} \end{bmatrix} \quad (3-2)$$

每个时间间隔矩阵表示为一个嵌入，因此对应的时间间隔嵌入矩阵表示为 $R \in \mathbb{R}^{l \times l \times d}$ 。

3.2.3 用户序列图

门控图神经网络 (GGNN) 更有利于提取复杂结构下的图嵌入，遗忘门会自动更新并获取节点当前的状态，使模型能够有选择地聚合节点嵌入，可以缓解同一时间内不同用户的交互带来的不准确性。用户序列图编码器的作用是生成用户在领域内的兴趣偏好特征嵌入 $H^{S,X}$ 、 $H^{S,Y}$ 。给定用户序列 S 将其构建为有向图 $G = (V_s, E_s)$ ，其中节点代表项目 $v_{s,i} \in V$ ，每条边 $(v_{s,i-1}, v_{s,i}) \in E_s$ 意味着用户在序列 S 中交互的项目 $v_{s,i}$ 在 $v_{s,i-1}$ 之后。由于项目在序列中可能会重复出现，为捕捉节点间的交互并防止模型过度依赖高频边，对每条边进行加权归一化，即边出现次数除以该边的开始节点出度以提高模型的泛化能力。将节点向量 $h \in \mathbb{R}^d$ 表示通过 GNN 学习到的潜在向量，其中 d 是维度。 A^X 、 A^Y 分别为 X 域和 Y 域的邻接矩阵。

GNN 节点更新。在聚集状态信息后，使用门控循环单元 GRU 更新每个节点信息，更新过程如图3-3所示。

$$\begin{aligned} a'_{s,i} &= A_{s,i} : [h_1^{t-1}, \dots, h_n^{t-1}]^T E + b \\ z'_{s,i} &= \sigma(W_z a'_{s,i} + U_z h_i^{t-1}) \\ r'_{s,i} &= \sigma(W_r a'_{s,i} + U_r h_i^{t-1}) \\ \tilde{h}_i^t &= \tanh(W_h a'_{s,i} + U_h (r'_{s,i} \odot h_i^{t-1})) \\ h_i^t &= \tilde{h}_i^t \odot z_i^t + h_i^{t-1} \odot (1 - z_{s,i}^t) \end{aligned} \quad (3-3)$$




图 3-3 节点更新图

$a'_{s,i}$ 用于捕捉节点 i 的上下文信息， $\sigma(\cdot)$ 为 *sigmoid* 函数， $\odot$ 为逐元素乘法。以上

就是用户域内序列项目交互的整合与更新过程，将上述传播过程重复多次以学习序列交互更高阶的项目特征，经过 GGNN 传播层进行节点嵌入，最终用公式3-4、公式3-5表示经过 t 步建模交互后序列中的项目表征。

$$H^{S,X} = \{h_1^{S,X}, h_2^{S,X}, \dots, h_t^{S,X}\} \quad (3-4)$$

$$H^{S,Y} = \{h_1^{S,Y}, h_2^{S,Y}, \dots, h_t^{S,Y}\} \quad (3-5)$$

通过叠加多层，得到一系列输出。为了完整地捕获跨层的图形信息，使用均值函数对它们进行平均，得到 X 域、 Y 域项目表示，如公式3-6所示。

$$H^X = \text{Mean}(H^{S,X}) + E^X, \quad H^Y = \text{Mean}(H^{S,Y}) + E^Y \quad (3-6)$$

3.2.4 跨域全局图

将用户所有序列聚合到跨域全局图中，为保留用户域间行为模式信息，使用 P 记录跨域序列中所有项目的位置顺序，便于将其应用于序列的表示学习。采用图卷积网络更新项目嵌入，并捕获协作信息。跨域全局图是一个无向二分图，根据用户在目标域和源域的交互序列，将每个用户节点链接到与之交互的项目节点，聚合相邻节点的特征，获得每个节点的新嵌入表示。为简化模型结构和减少参数量，采用了简单的加权和聚合器，消息传播策略形式如公式3-7所示。

$$E^{(k+1)} = (D^{\frac{1}{2}} A D^{-\frac{1}{2}}) E^{(k)} \quad (3-7)$$

其中， A 为跨域全局图的邻接矩阵， $D_{ii} = \sum_j A_{ij}$ 为相应的对角度矩阵。通过叠加多层得到项目表示 $H^G = \{h_1^G, h_2^G, \dots, h_t^G\}$ ，同样对每层信息进行平均，公式3-8得到跨域全局图的最终项目嵌入表示。

$$H = \text{Mean}(H^G) + E^G \quad (3-8)$$

3.2.5 序列表示模块

在以往的研究中，GRU 和自注意力机制通常用于细化用户的序列级表示，生成跨域序列推荐中的序列编码。这些方法捕捉到项目在序列中的顺序性，但忽略了项目的不同时间间隔具有不同的影响。例如，时间戳越近的项对下一项的影响越大，为进一步增强项目表征的学习，将时间间隔信息融入到多头注意力机制中，本文提出了时间间隔注意力编码器。该编码器由多头注意力和逐点前馈网络组成，多头注意力捕获交互序列中复杂项目依赖关系，逐点前馈网络赋予非线性投影以输出最终的序列表示。对序列 S 中的每一项加入其位置嵌入，得到多头注意力的初始输入嵌入 M^0 。

$$M^0 = [e_1 + p_1, e_2 + p_2, \dots, e_l + p_l] \quad (3-9)$$

按比例扩展的点积注意来建模序列关系, 将其表示为 f_{att} 。由于多层块的递归性质, 使用第 x 层来解释该模块。对于项目 p 的第 x 层输入 M_p^x , 通过时间间隔注意力编码器输出的计算公式如3-10所示。

$$Z_p^x = \sum_{q=1}^l f_{att}(M_p^x W_Q^x, M_q^x W_K^x) \cdot M_q^x W_V^x \quad (3-10)$$

投影矩阵 $W_Q^x, W_K^x, W_V^x \in \mathbb{R}^{d \times d}$ 是注意力头的三个权重参数, $Z_p^x \in \mathbb{R}^d$ 是项目 p 在第 x 关注层之后的输出。在公式3-10中构造 f_{att} 将时间的影响应用到序列中, 加权的注意力权重如公式3-11所示。

$$f_{att}(Q_p, K_q) = \frac{\exp(w_{pq}) \cdot \theta_{pq}}{\sum_{k=1}^l \exp(w_{pk}) \cdot \theta_{pk}}, w_{pq} = \frac{Q_p K_q^T}{\sqrt{d}} \quad (3-11)$$

当 $\theta = 1$ 表示一个缩放点积注意力, $\sqrt{d}$ 是影响因子。然后从 M_p^x, M_q^x 以及项目 p 和项目 q 之间的时间间隔 t_{pq} 学习 θ_{pq} 。

$$\theta_{pq} = (M_p^x W_L^x + M_q^x W_K^x + t_{pq}) W_L^x + b_L \quad (3-12)$$

其中 $W_L^x \in \mathbb{R}^d, b_L \in \mathbb{R}^1$, 时间间隔嵌入 $t_{pq} \in \mathbb{R}^d$ 来自时间间隔嵌入 $R \in \mathbb{R}^{l \times l \times d}$ 。堆叠注意力层之后, 可能会出现梯度消失、训练时间增加等问题, 为实现稳定的训练过程并防止模型过拟合, 下一层的 M^{x+1} 是将 Z^x 经过残差连接^[54]、层归一化^[55]和点式前馈网络^[47]生成的, 如公式3-13所示。时间间隔编码器结构如图3-4所示。

$$\begin{aligned} FFN(Z) &= \max(0, ZW_1 + b_1)W_2 + b_2 \\ M^{x+1} &= LN(M^x + FFN^x(Z^x)) \end{aligned} \quad (3-13)$$




图 3-4 时间间隔编码器

最后使用 $TiAttEncoder$ 函数来表示整个编码过程。对于不同的序列输入，得到如下项目增强表示。

$$\begin{aligned} H_X &= TiAttEncoder(H^X, E^X) \\ H_Y &= TiAttEncoder(H^Y, E^Y) \\ H_G &= TiAttEncoder(H, E^G) \end{aligned} \quad (3-14)$$

其中, $H_X \in \mathbb{R}^{l \times d}$, $H_Y \in \mathbb{R}^{l \times d}$, $H_G \in \mathbb{R}^{l \times d}$ 分别表示 X 域、 Y 域和跨域全局序列交互的顺序输出。

3.2.6 跨域偏好对比学习和模型预测

H_X 、 H_Y 是独立地从域内序列 S_X 、 S_Y 中学习到的, 它们可能倾向于领域内的用户部分偏好。由于结合用户跨域行为模式能更好地捕捉用户偏好, 因此本文提出了基于对比学习的辅助任务来增强跨域序列的表示, 以提高单域序列和跨域序列项目之间的相关性。以 X 域为目标域为例, 利用 $softmax$ 函数^[56]计算对应 Y 域中项目的概率分布, 识别跨领域序列中来自 Y 域的哪些项目对 X 域推荐有帮助, 公式3-15表示计算跨域序列中源域项目与目标域中项目的相关性。

$$\phi_Y = softmax(H_Y \cdot (mean(H_X))) \quad (3-15)$$

如构建跨域序列 $S = [x_1, y_1, x_2, y_2, \dots, x_i, y_i]$, 当其中一个交互 $\phi_{y_i} < 0.5$ 时表示其与 X 域项目的相关性较小, 使用掩码替换。经过掩码替换可以将不相关或噪声较大的样本从中排除, 有助于学习重要的特征, 替换后的序列为 $\tilde{S}_X = [x_1, y_1, x_2, [m], \dots, x_i, [m]]$, 其中 $[m]$ 表示掩码, 使用公式3-14对该序列进行编码得到对比序列 $\widehat{h}_s^X$ 。跨域序列 S 将其输出 H_G 按不同的区域分为两部分, 对于 X 域, 有:

$$f_S^X(\cdot) = Mean\{H_{G,S_k} : S_k \in X\} \quad (3-16)$$

$$h_s^X = f_s^X(H_G), \widehat{h}_s^X = f_s^X(\widehat{H_G^X}) \quad (3-17)$$

$f_S^X(\cdot)$ 是用于提取和计算属于 X 域序列中的项目对应的输出表示的函数。最后, 遵循对比学习中的 InfoNCE^[57]损失来构造对比辅助任务。

$$\mathcal{L}_s^X = -\log \frac{\exp(sim(h_s^X, \widehat{h}_s^X))}{\exp(sim(h_s^X, \widehat{h}_s^X)) + \sum_{S'} \exp(sim(h_s^X, h_{S'}^X))} \quad (3-18)$$

其中 $sim(\cdot)$ 用于计算两个向量之间的相似度, S' 表示同一批次内其他用户的跨域序列。同样的方式, 可以计算 Y 域的对比辅助任务 $\mathcal{L}_s^Y$ 。

基于生成的序列表示 H_X 、 H_Y 、 H_G , 采用两种顺序目标进行优化。不同类型的序列设计不同的训练目标, 分为单域训练目标和跨域训练目标。为简化计算, 在输入序列上采用填充技术以保持序列的长度一致。如 $S_X = \{x_1, < pad >, x_2, < pad >, x_3\}$,

$S_Y = \{y_1, < pad >, y_2, y_3, < pad >\}$, $S = \{x_1, y_1, x_2, y_2, x_3\}$, 本文使用常数零向量作为 $< pad >$ 的项目嵌入。

单域训练目标: 使用序列推荐中最常用的训练策略来优化模型, 利用用户历史序列训练模型来推荐下一个项目。对于 X 域, 为了利用跨域序列的辅助信息, 模型将域内序列和跨域序列中对应的项目表示进行求和, 然后计算 X 域中所有项目的预测概率。

$$\mathcal{L}_x = \sum_k -\log P_X(x_{k+1} | [x_1, < pad >, x_2, < pad >, x_3, \dots, x_k]), \quad (3-19)$$

$$P_X(x_{k+1} | [\dots, x_k]) = \text{softmax}(H_{X_k} W_X, H_{S_k} W_X) \quad (3-20)$$

其中 $H_{X_k} \in \mathbb{R}^{1 \times d}$ 和 $H_{S_k} \in \mathbb{R}^{1 \times d}$ 是单域和跨域中位置 k 处的序列表示, $W_X \in \mathbb{R}^{d \times n}$ 是用于预测的可学习参数矩阵。

跨域训练目标: 在跨域序列中用户通常表现出不同的偏好, 一个领域的偏好可能会影响另一个领域的后续交互, 并且不同领域包含的交互数量也不同。为避免预测结果被数据较多的领域主导, 遵循 $C^2DSR^{[58]}$, 提出如下跨域平衡目标函数:

$$\mathcal{L}_s = \sum_k \mathcal{L}_s(S, k) = \begin{cases} -\log P_S^X(x_{k+1} | [x_1, y_1, x_2, \dots, y_k]) \\ -\log P_S^Y(y_{k+1} | [x_1, y_1, x_2, \dots, y_k]) \end{cases} \quad (3-21)$$

$$P_S^X(x_{k+1} | [x_1, y_1, x_2, \dots, y_k]) = \text{softmax}(H_{S_k} W_X) \quad (3-22)$$

$$P_S^Y(y_{k+1} | [x_1, y_1, x_2, \dots, y_k]) = \text{softmax}(H_{S_k} W_Y) \quad (3-23)$$

为便于优化, 将损失函数分解为两个相互独立的部分, 即使跨域序列在另一个领域包含的交互数据较多时, 也能保证模型对目标域的预测能力。总体训练目标如公式3-24所示。

$$\mathcal{L} = \lambda(\mathcal{L}_x + \mathcal{L}_y + \mathcal{L}_s) + (1 - \lambda)(\mathcal{L}_s^x + \mathcal{L}_s^y) \quad (3-24)$$

其中 $\mathcal{L}_x$ 、 $\mathcal{L}_y$ 、 $\mathcal{L}_s$ 表示顺序推荐任务, $\mathcal{L}_s^x$ 、 $\mathcal{L}_s^y$ 表示对比学习辅助任务, λ 表示平衡这两类任务的因子。模型训练详细过程如算法 1 所示。

Algorithm 1 模型训练过程

输入: 序列 S_X 、 S_Y , 并构建混合序列 S , 网络层数 L

- 1: **for** each mini-batch sequences s^x 、 s^y 、 s **do**
 - 2: 模型得到单域、跨域序列表示: $H_x, H_y, H_G \leftarrow \text{TAGNN}(s^x, s^y, s, L)$
 - 3: 计算单域序列和混合序列预测概率: P_x, P_y, P_s
 - 4: 计算跨域序列项目预测概率: P_s^x, P_s^y
 - 5: 单域和跨域序列训练目标: $\mathcal{L}_x, \mathcal{L}_y, \mathcal{L}_s$
 - 6: 对比辅助任务训练目标: $\mathcal{L}_s^x, \mathcal{L}_s^y$
 - 7: 得到总体训练目标: $\mathcal{L} \leftarrow \lambda(\mathcal{L}_x + \mathcal{L}_y + \mathcal{L}_s) + (1 - \lambda)(\mathcal{L}_s^x + \mathcal{L}_s^y)$
 - 8: **end for**
-

以 X 域为目标域, 将目标域和跨域序列中对应项目的表示相加, 计算用户选择下一个项目的概率, 并将目标域中预测分数最高的项目作为用户下一个推荐项。

$$\begin{aligned} & \operatorname{argmax}_{x_{i+1} \in X} P_X(x_{i+1} | S_X, S_Y), \\ & P_X(x_{i+1} | S_X, S_Y) = \operatorname{softmax}(H_{X_i} W_X + H_{X_i} W_S) \end{aligned} \quad (3-25)$$

遵循类似的操作为 Y 域预测下一项被推荐的概率。

3.3 模型性能验证

3.3.1 数据集

利用公共数据集 Amazon^① (亚马逊) 进行实验, 该数据集中包含来自多个领域的用户交互 (例如, 用户 ID、项目 ID、评分、时间戳) 和一些项目元信息 (描述、图像、类型)。与其它推荐数据集相比, 亚马逊数据集包含多个领域重叠用户交互, 适用于跨域序列推荐。具体来讲, 选择四个领域生成两个跨域序列推荐场景进行实验: “Movie-Book” 和 “Food-Kitchen”, 其中, Movie 域包含电影观看记录, Book 域涵盖了读书记录, Food 域包含食品购买记录, Kitchen 域包含家具购买记录。在实验中, 给定两个数据集 (如 Movie 和 Book), 每个数据集都可以作为源数据域或目标数据域。即该模型可以使用 Movie 作为源域数据, Book 作为目标域数据集进行评估, 也可以使用 Book 作为源域数据, Movie 作为目标域数据集。

为满足跨域特性, 选择在两个域都有交互的用户, 由于本文没有针对冷启动的用户或项目, 所以保留有 10 个以上交互的用户和频率大于 10 的项目。为满足一段时间内的用户交互组成的序列特征, 将用户在两个领域的交互序列按照时间排序, 然后将序列拆分成几个小序列, 每个小序列包含一个周期内的交互, 即对于 “Movie-Book” 数据集是一个月, “Food-Kitchen” 数据集是一年。另外, 还保证序列都包含至少来自每个域的 3 个项目。表3-1显示了处理后的数据集的统计结果。

表 3-1 两组数据集统计表

领域	用户数	项目数	混合序列数	平均序列
Movie	15351	36845	73867	11.98
Book	15351	63937		
Food	16578	29207	50696	9.91
Kitchen	16578	34886		

^①<https://jmcauley.ucsd.edu/data/amazon/>

3.3.2 评价指标

本文按照 8:1:1 的比例将数据集划分为训练集、验证集、测试集。为评价 TAGNN 方法和基线方法的推荐性能, 本文采用留一法^[59]来评估模型, 对于每个验证/测试项目将会随机选择 999 个用户未交互的项目作为负样本。使用推荐系统中常用的命中率 (Hits Ratio, HR) 和归一化折损累计增益 (Normalized Discounted Cumulative Gain, NDCG) 评估模型推荐性能。HR@K 关注的是推荐列表中是否包含了用户真实喜欢的物品, 在 K 个推荐项中是否包含用户真实感兴趣的物品 (即正样本)。如果用户实际感兴趣的物品出现在前 K 个推荐中, 那么这次推荐就被认为是“命中”的。HR@K 强调的是准确性, 其衡量了推荐系统的覆盖率。

$$HR@K = \frac{1}{n} \sum_{i=1}^n hits(i) \quad (3-26)$$

n 表示用户总数量, $hits(i)$ 表示第 i 个用户要访问的物品是否在推荐列表中, 是则为 1, 否则为 0。

NDCG@K 是用于评估推荐系统排序质量的一种指标, 不仅关注推荐列表的质量, 同时也考虑了推荐物品的相关性以及其在推荐列表中的位置。对于每个用户, 根据推荐列表中物品的相关性进行排序, 对排在列表前面的物品给予更高的权重, 因为用户有可能仅查看推荐列表的前几个物品。NDCG@K 的计算分为两个步骤, 首先计算折扣累计增益值 DCG@K (Discounted Cumulative Gain), 由列表中前 N 个项目的相关性和位置加权得出。

$$DCG@K = \sum_{i=1}^N \frac{2^{rel_i} - 1}{\log_2(i + 1)} \quad (3-27)$$

rel_i 是第 i 个物品的相关性, N 是推荐列表的长度。然后计算归一化的 DCG (NDCG@K)。

$$NDCG@K = \frac{DCG@K}{IDCG@K} \quad (3-28)$$

其中, IDCG@K 是理想情况下的 DCG@K, 表示推荐列表按照真实相关性降序排列的情况下的 DCG@N 值。对于 K 值的选取, 本文选择大多数论文中采用的 K=10。

3.3.3 实验环境与设置

实验使用的设备环境配置如表 3-2 所示。在本章实验中, 模型参数设置如下: 嵌入大小设置为 64, dropout 比率设置为 0.3, L_2 正则化系数设置为 0.0005, 学习速率设置为 0.001, 为了加快训练过程, 批量大小均设置为 256, 训练周期为 100。平衡因子 λ 范围选择从 0.1 到 1, 步长为 0.1, GNN 层数从 {1, 2, 3, 4, 5} 内选择。初始化策略采用 Xavier 方法^[60]来随机初始化模型参数, 使用 Adam^[61]优化算法更新所有参数。所有参数都将在验证集上进行调整, 所有模型都将进行三次实验, 并记录 HR@10 和 NDCG@10 的平均结果。

表 3-2 实验环境表

配置	详情
CPU	Xeon(R) Platinum 8350C
GPU	RTX 3090(24GB)
Memory	42GB
Operating System	ubuntu18.04
CUDA	11.1
Python	3.8.0
PyTorch	1.7.1

3.3.4 对比实验结果及分析

将 TAGNN 模型与传统推荐、序列推荐以及跨域推荐等多个模型在相同的基本条件下进行对比实验，以充分证明本文所提出的 TAGNN 模型的有效性。接下来，将简要阐述对比模型方法。

(1) 传统推荐方法

BPR-MF^[6]：是一种常见的矩阵分解方法。面向隐反馈偏好数据的排序模型，基于贝叶斯个性化排序的矩阵分解（Matrix Factorization, MF）模型，使用用户历史行为预测用户对未知物品的偏好程度，通过最大化后验概率来优化模型参数。

(2) 序列推荐方法

GRU4Rec^[62]：将递归神经网络（RNN）应用于推荐系统，通过对整个会话进行建模，利用门控单元 GRU 对用户行为序列信息进行编码，引入了与会话并行的小批量的输出采样和排序损失函数。

TiSASRec^[63]：提出时间间隔感知的自注意序列推荐模型，通过在自注意力层中加入相对位置编码和时间间隔信息，以显式地建模用户行为序列中项目之间的时间间隔和先后顺序。

SR-GNN^[30]：将序列化的问题转换为图结构，所有会话序列建模为有向图，通过 GNN 学习每个项目的隐向量表示。然后通过自注意力模块捕捉用户的短期兴趣，以达到同时捕获长期和短期兴趣共存的向量表示。

(3) 跨域推荐方法

NCF-MLP^[64]：将经典的神经协同过滤（NCF）模型用于跨域推荐，通过 MLP 网络学习用户和项目的表示。为了适应两个领域，其通过两个独立的基础 MLP 网络以及一个共享的初始用户嵌入层来学习用户/项目的表示。

Conet^[25]：是一种经典的跨域推荐方法，通过两个基础网络对两个领域的交互进行建模，然后使用一个跨域交叉网络在两个域的基础网络之间传递领域知识。

π -Net^[28]：是一个关于跨域序列推荐的模型，采用并行信息共享网络，该网络通过

共享用户账户同时对两个领域进行推荐。其中网络包含共享账户过滤单元用于学习用户特定的表示，跨域传输单元用于传递用户信息。

MIFN^[39]：模型采用行为转移单元从行为信息流中提取用户相关信息，然后使用知识转移单元连接用户在不同领域之间的偏好。此外，利用跨域图卷积网络区分知识图谱中 useful 信息并进行融合，最后基于行为信息和知识信息生成推荐。

C²DSR^[58]：使用图卷积网络挖掘序列间项目之间的协同关系，然后利用自注意编码器捕获序列间项的顺序关系，并在此基础上设计两种不同的顺序训练目标获取用户的单域表示和跨域表示。

LEA-GCN^[65]：其在图卷积网络中保留邻域聚合组件并使用单层聚合协议，以捕获来自两个领域的协同过滤信号，同时设计了一种双通道外部注意组件，该组件通过轻量级线性结构计算所有项目之间的相关性。

表3-3、表3-4展示了三类基线模型与本章所提出的 TAGNN 模型在两组场景数据集上的实验结果，可以直观地看到 TAGNN 模型的 NDCG@10 和 HR@10 指标均在对比模型上取得了明显的提升。

表 3-3 不同模型在 Movie-Book 数据集上的性能对比

模型	Movie		Book	
	NDCG@10	HR@10	NDCG@10	HR@10
BPR-MF	0.0280	0.0495	0.0117	0.0215
GRU4Rec	0.0363	0.0545	0.0156	0.0237
TiSASRec	0.0372	0.0563	0.0171	0.0281
SR-GNN	0.0378	0.0581	0.0166	0.0272
NCF-MLP	0.0286	0.0525	0.0122	0.0223
CoNet	0.0321	0.0536	0.0128	0.0231
π -Net	0.0417	0.0611	0.0203	0.0284
MIFN	0.0525	0.0833	0.0232	0.0317
C ² DSR	0.0575	0.0955	0.0245	0.0375
LEA-GCN	0.0619	0.1066	0.0274	0.0435
TAGNN	0.0733	0.1235	0.0328	0.0521

传统推荐模型 BPR-MF 在两个场景数据集上的推荐效果最差。因为该模型通过将静态的用户-物品评分矩阵分解为两个低维度矩阵，即用户隐特征矩阵和项目隐特征矩阵的乘积来预测未知项目的评分，然而用户只与极少数项目交互，会导致评分矩阵稀疏，从而导致模型的效果较差。跨域推荐模型 NCF-MLP 和 CoNet 性能优于 BPR-MF 模型，验证了考虑域间差异和跨域知识转移有助于更好地领域适应。NCF-MLP 模型使用 MLP 学习复杂的用户-物品交互特征，其更依赖于单个领域内的数据；Conet 模型通过引入交叉学习，两个 MLP 网络结构通过交叉连接共享信息，在数据稀疏的领域通过借助其它领域的数据来增强目标域推荐。序列推荐模型，在混合顺序推荐数据集中效果显

表 3-4 不同模型在 Food-Kitchen 数据集上的性能对比

模型	Food		Kitchen	
	NDCG@10	HR@10	NDCG@10	HR@10
BPR-MF	0.0413	0.0592	0.0169	0.0305
GRU4Rec	0.0612	0.0911	0.0310	0.0522
TiSASRec	0.0824	0.1214	0.0409	0.0664
SR-GNN	0.0835	0.1227	0.0413	0.0684
NCF-MLP	0.0431	0.0686	0.0203	0.0365
CoNet	0.0424	0.0735	0.0261	0.0471
π -Net	0.0860	0.1175	0.0373	0.0667
MIFN	0.0901	0.1271	0.0429	0.0708
C ² DSR	0.0962	0.1419	0.0486	0.0809
LEA-GCN	0.1001	0.1493	0.0524	0.0882
TAGNN	0.1079	0.1609	0.0575	0.0933

著优于传统推荐方法和跨域推荐，这是因为捕捉交互的顺序特征能够提高推荐的性能。GRU4Rec 模型使用门控循环单元 GRU 处理序列中的时间依赖关系，对用户短期偏好有较好的捕捉能力，但当处理长序列时可能会遇到梯度消失或梯度爆炸问题；TiSASRec 模型通过自注意力机制捕捉序列中长距离的依赖关系，同时考虑了时间间隔信息更好地理解用户行为的时间动态；SR-GNN 将序列转换为图结构，可以有效地处理稀疏数据，更自然地捕捉用户行为之间复杂的转移关系。

跨域序列推荐模型中， π -Net 同样使用 GRU 作为基本框架，相比于 GRU4Rec 模型， π -Net 的效果更好，这表明识别领域之间的差异并跨域传输知识可以提高推荐性能。MIFN 使用知识图谱来建模用户在两个不同领域之间的行为转移和兴趣迁移，对领域之间的信息流动有较强的适应性，但其忽略了用户序列之间的行为模式。C²DSR 模型通过序列感知的方式共享两个领域的信息，结合单域和跨域序列信息具有更好的预测性能。LEA-GCN 模型使用单层聚合协议传播跨域序列图嵌入，其简化了图卷积网络的结构并优化了序列编码器的复杂性。TAGNN 采用 GGNN 提取用户域内序列图的动态变化，利用 GCN 学习跨域全局图中的项目协作信息，同时融入时间间隔注意力机制更好地理解用户序列内的项目特征，有助于提高模型的精度。其表现在“Movie-Book”数据集，和 LEA-GCN 模型相比，Movie 域的 NDCG 和 HR 指标分别提升了 1.14%、1.7%，在 Book 域上的 NDCG 和 HR 指标分别提升了 0.5%、0.8%，在“Food-Kitchen”数据集上也达到相同的效果。实验结果证明，本文提出的 TAGNN 模型在跨域序列推荐场景中能有效捕捉用户在单域和跨域序列中项目的复杂交互和依赖关系，具有一定的优越性。

3.3.5 消融实验

为进一步研究 TAGNN 模型的细节部分，本节进行了四组消融对比实验。通过对核心创新点的消融，进一步验证 TAGNN 模型的有效性和适用性。接下来简要介绍消融模型的内容。

w/o-cross: 表示不考虑跨域序列信息，仅在单个领域内进行序列推荐。

w/o-graph: 在 TAGNN 模型上去掉了图编码器，仅基于显示的项目 ID 信息表示跨域序列中项目的特征表示。

w/o-time: 不考虑时间间隔信息，且利用标准的自注意力机制来建模顺序表示。

w/o-cl: 从 TAGNN 中移除对比学习辅助任务，并且仅利用单域推荐任务、跨域推荐任务。

表3-5、表3-6展示了 TAGNN 模型在 Movie-Book 和 Food-Kitchen 上的消融实验的 NDCG 和 HR 值，图 3-3 可以更直观地显示不同变体的性能。

表 3-5 不同模块在 Movie-Book 上的性能

模型	Movie		Book	
	NDCG@10	HR@10	NDCG@10	HR@10
w/o-cross	0.0593	0.1016	0.0223	0.0331
w/o-graph	0.0658	0.1081	0.0263	0.0408
w/o-time	0.0645	0.1122	0.0246	0.0399
w/o-cl	0.0705	0.1203	0.0305	0.0483
TAGNN	0.0733	0.1235	0.0328	0.0521

表 3-6 不同模块在 Food-Kitchen 上的性能

模型	Food		Kitchen	
	NDCG@10	HR@10	NDCG@10	HR@10
w/o-cross	0.0917	0.1332	0.0415	0.0676
w/o-graph	0.0960	0.1467	0.0507	0.0846
w/o-time	0.0994	0.1470	0.0518	0.0869
w/o-cl	0.1065	0.1554	0.0541	0.0904
TAGNN	0.1079	0.1609	0.0575	0.0933

相对而言，w/o-cross 模型在两组数据集上整体表现较差，NDCG 值下降了近 1.6%。在 TAGNN 模型中，引入跨域序列可以利用用户在其它域的行为模式，帮助推荐系统缓解数据稀疏性问题，为用户提供更合理的推荐。由此可见，仅仅依靠单域推荐对用户偏好建模，会很容易被单一领域限制，故其推荐效果较差。w/o-graph 模型直接采用项目嵌入的方式，忽视了用户序列中项目之间以及跨域序列的交互作用，仅使用项目的嵌入信息不足以充分理解用户与项目间复杂的关系。证明了图神经网络的引入能够提升模型

的性能，用户在领域内的兴趣往往是复杂、动态变化的，GGNN 通过门控单元（GRU）学习节点之间的长期依赖关系，有助于理解用户的长期偏好提供精准的用户行为表示。图卷积网络在处理跨域全局信息时，通过全局结构的学习有助于整合来自不同领域的信息。w/o-time 模型表明不考虑项目时间间隔，在 Food-Kitchen 和 Movie-Book 数据集上的推荐性能较低。也就证明了将时间间隔信息融入注意力模块中学习项目的交互特征，有利于捕捉用户兴趣的动态变化，从而得到更准确的用户项目表示。w/o-cl 模型通过对比学习辅助任务来增强跨域序列的表示，有利于提高单域序列和跨域序列项目之间的相关性，实验结果表明结合跨域行为模式有利于模型性能的提升。




图 3-5 在两组数据集上的消融实验

3.3.6 超参数学习

本节探讨超参数对模型性能的影响，主要是 GNN 模块层数、平衡因子。

(1) GNN 模块层数

对于图神经网络层数 L ，图3-6展示了在 Food 域和 Kitchen 域上的性能。TAGNN 模型基于图神经网络的方式分别捕获用户序列图和跨域全局图中的项目特征，图神经网络的层数会影响模型提取序列项目表征的效果。将层数范围设置为 $\{1,2,3,4,5\}$ ，实验结果表明在 Food-Kitchen 数据集上，增加 GNN 模块层数可以显著提升性能，证明利用高阶

用户序列信息可以有效改善推荐性能。GNN 层数为 3 时模型性能最好，当进一步增加网络层数时，模型性能开始下降。模型的性能先上升后下降这说明堆叠项目表征提高了模型的复杂度，但不一定会提升模型性能，深度图神经网络容易导致过平滑问题，这也就限制了模型捕捉协作信号的有效性。因此， L 选择 3 是一个比较合理的值。




图 3-6 不同图神经网络模块层数对 TAGNN 性能的影响

(2) 平衡因子




图 3-7 不同 λ 对 TAGNN 性能的影响

图3-7显示了 Food 领域和 Kitchen 领域在 HR 和 NDCG 指标上的预测性能。超参数 λ 被引入作为一个权衡参数，以平衡推荐任务和对辅助任务。考虑从 0.1 到 1 的不同 λ 值，其中 $\lambda=1$ 表示模型没有使用对比信息最大化辅助任务，只利用推荐任务进行训练。实验结果显示，当 $\lambda=0.1$ 时模型表现最差， λ 在 $[0.3, 0.7]$ 范围内模型显示出更优越和稳健的结果，即使是最坏情况下，TAGNN 模型效果仍然优于其它基线模型。将 λ 设置为更大的数值时可能会导致训练收敛速度更快，也就是 $\lambda = 0.6$ 是模型效果和效率之间的平衡选择。

3.4 本章小结

本章中，首先分析了现有跨域序列推荐的不足，并提出了新的改进思路与创新模型的实现方法，且对基于时间感知的图神经网络跨域推荐模型（TAGNN）的功能和模块结构进行了详细介绍。最后在两组数据集上进行了实验验证，并将 TAGNN 与三种推荐算法模型（传统推荐、序列推荐、跨域推荐）进行模型性能对比，验证了本章所提出的 TAGNN 模型的优越性。

第4章 基于注意力和时间感知的图神经网络跨域推荐

本章主要介绍了层级注意力图卷积网络,其中包括节点级消息传递、领域级消息传递、信息聚合等过程。接着使用该图卷积网络与第三章模型(TAGNN)建立完整的跨域推荐模型,其中包括输入和嵌入层、用户序列图、层级注意力图卷积网络、图嵌入聚合、时间间隔注意力编码器、对比辅助函数和损失函数等。最后通过对比实验和消融实验证明了层级注意力图卷积网络在挖掘不同领域用户偏好上的有效性。

4.1 引言

推荐系统已成为电商网站、社交网络等在线平台不可或缺的一部分。推荐系统为用户提供个性化的推荐服务,帮助用户发现相关内容从而提高整体体验。如今,用户更倾向于在不同平台上注册,以访问特定领域的服务。传统的推荐方法通常侧重于推荐单个领域内的项目或内容。随着来自多个领域的数据的可用性不断提高,对跨领域推荐的需求越来越大,跨域推荐旨在利用相关域的辅助信息来提高目标域的性能,以缓解数据稀疏性问题。目前大多数的跨域序列推荐研究采用RNN、GNN或Transformer等模型对复杂的用户-项目交互进行建模,并在不同领域之间传递特定领域的知识。

在跨域推荐中,基于图卷积方法大多数都是平等地对待不同领域中的项目,所有项目信息不区分重要程度地传递给用户节点。例如,偏好传播图网络模型^[33]通过两个域的用户-项目交互构建统一的跨域偏好图,以捕捉用户偏好在图中的传播,然而它在聚合阶段对来自不同域的所有项目一视同仁,并不区分不同域内项目的贡献度。但实际生活中,对用户而言,不同项目具有不同的重要性。特别是在向目标域用户推荐时,不同领域的项目对推荐结果的影响是有差别的,通常情况下,目标域内的项目应当有更高的影响力,反映出用户对不同领域项目的不同偏好程度。如果推荐系统在进行推荐时不区分项目重要程度,那么从其它领域学习到的信息不但没有帮助,还有可能产生负转移问题,降低目标域的推荐性能。

为了解决上述问题,在第三章TAGNN模型的基础上,本文提出了一个新的基于注意力和时间感知的图神经网络跨域推荐模型(Attention and Time-Aware Graph Neural Network for Cross-Domain Recommendation, ATAGNN)。为区分不同领域的项目对用户选择目标域项目偏好的影响,提出层级注意力图卷积网络(Graph Convolutional Networks with Hierarchical Attention, HAGCN),将不同领域的交互数据构建为统一的跨域顺序(CDS)图,基于该图模型利用源域和目标域的交互节点学习嵌入,使用LightGCN作为在CDS图上传播特定领域消息的基本图编码器。在消息传递过程中,通过从节点级和领域级两方面来估计项目节点的重要性。此外,为更好地结合跨域信息,通过对用户序列图和跨域全局图学习到的图嵌入进行聚合,并将得到的聚合嵌入和跨域全局图嵌入通

过序列编码器得到目标域和跨域中的用户顺序偏好。

4.2 模型构建

4.2.1 层级注意力图卷积网络

构造跨域全局图在建模用户和项目之间的复杂关联（即两个领域的用户项目交互和不同项目之间的顺序关系）方面是有效的。同样的，将用户、项目节点初始化为低维稠密的向量表示 $e_u \in \mathbb{R}^d$ 、 $e_{X_i} \in \mathbb{R}^d$ 、 $e_{Y_j} \in \mathbb{R}^d$ 分别表示用户 $u \in U_C$ 、 $X_i \in X$ 、 $Y_j \in Y$ 的嵌入向量， d 为嵌入大小。基于构建的交互图，采用消息传递策略传递高阶交互的消息。

利用 X 域和 Y 域中的所有交互序列数据构造统一的交互图 $G = (N, E)$ ， N 表示节点集合， E 表示边集合，如图4-1所示。其中 N 由用户节点和项目节点组成：用户 $u_k \in U_X \cup U_Y, k \in \{1, \dots, N_X + N_Y - N_C\}$ ，项目 $X_m \in I, m \in \{1, \dots, N_i\}, Y_n \in J, n \in \{1, \dots, N_j\}$ 。为保留用户域间行为模式信息，使用 p 记录混合序列中所有项目的位置顺序，便于将其应用于序列级表示学习。




图 4-1 基于不同领域用户交互图

1. 消息传递

$X_i \in N_{X_i}^u$ 和 $Y_j \in N_{Y_j}^u$ 表示用户 u 在 X 域和 Y 域中的第 i 个和第 j 个项目节点， N_{X_i} 、 N_{Y_j} 表示用户 u 在 X 域和 Y 域中项目邻居集合。与 LightGCN 模型一致，去除了其中的特征变换和非线性激活函数。X 域的项目 $X_i \in N_{X_i}^u$ 传递到用户 u 的消息定义为如下表示：

$$m_{u \leftarrow X_i} = \gamma_{u \leftarrow X_i} e_{X_i} \quad (4-1)$$

其中， $m_{u \leftarrow X_i}$ 表示从 X_i 传递给用户 u 的消息。 $\gamma_{u \leftarrow X_i}$ 表示控制从项目节点传递信息的参数，通过所提出的层级注意力机制计算得到的。从用户 u 到项目 $X_i \in N_{X_i}^u$ 的消息传递为： $m_{X_i \leftarrow u} = \gamma_{X_i \leftarrow u} e_u$ 。同样，给定 Y 域中的项目 $Y_j \in N_{Y_j}^u$ 用类似的方式表示消息传递 $m_{u \leftarrow Y_j}$ 、 $m_{Y_j \leftarrow u}$ 。

(1) 节点消息传递，如图4-2所示。




图 4-2 节点消息传递

由于不同邻居对领域内当前节点用户 u 或项目 i 有不同的影响。使用节点级注意力来估计同一领域内的邻居节点对当前节点的影响。则获取 X 域中每个项目节点对用户节点的重要程度的相似度权重表示为:

$$\gamma_{u \leftarrow X_i}^N = \frac{\exp(\text{sim}(e_u, e_{X_i}))}{\sum_{X_i \in N_{X_i}^u} \exp(\text{sim}(e_u, e_{X_i}))} \quad (4-2)$$

$\text{sim}(\cdot)$ 为相似度度量函数, 采用余弦相似度计算当前节点与其邻居节点的相似度。同样的方式可计算出用户 u 对项目 X_i 的权重 $\gamma_{X_i \leftarrow u}^N$ 。

(2) 领域消息传递, 如图4-3所示。




图 4-3 领域消息传递

为充分捕捉用户在不同域的贡献, 采用领域级注意力估计不同域在节点间传递消息时的影响。计算如 X 领域对用户的领域级注意力, 将该域内所有相邻节点对目标用户的影响进行聚合, 然后在两个域之间进行归一化处理。X 域中用户的域级注意力权重如公式4-3所示。

$$\gamma_{u \leftarrow I}^D = \frac{\exp(\text{sim}(e_u, e_{X_i}))}{\sum_{X_i \in I} \exp(\text{sim}(e_u, e_{X_i})) + \sum_{Y_j \in I} \exp(\text{sim}(e_u, e_{Y_j}))} \quad (4-3)$$

对于领域中的重叠用户, 层级注意力可以区分域内不同邻居节点和域间不同邻居节点的重要性。给定 X 域用户 u 的最终权重计算公式如4-4所示。

$$\gamma_{u \leftarrow X_i} = \gamma_{u \leftarrow X_i}^N \gamma_{u \leftarrow I}^D \quad (4-4)$$

对于非重叠用户的所有交互项目, 由于其只在单个领域内存在邻居节点, 因此嵌入更新过程中只使用节点级注意力, 其权重计算公式如4-5所示。

$$\gamma_{u \leftarrow X_i} = \gamma_{u \leftarrow X_i}^N \quad (4-5)$$

2. 消息聚合

通过聚合不同领域中从邻居节点传递的消息来更新用户在跨域全局图中项目的嵌入。

$$\begin{aligned} e_u &= \text{LeakyReLU} \left(\sum_{X_i \in N_{X_i}^u} m_{u \leftarrow X_i} + \sum_{Y_j \in N_{Y_j}^u} m_{u \leftarrow Y_j} \right) \\ e_{X_i} &= \text{LeakyReLU} \left(\sum_{u \in N_u^i} m_{i \leftarrow u} \right) \\ e_{Y_j} &= \text{LeakyReLU} \left(\sum_{u \in N_u^j} m_{j \leftarrow u} \right) \end{aligned} \quad (4-6)$$

采用 LeakyReLU 激活函数。最后通过串联和平均池化得到最终的节点表示, $\parallel$ 为串联操作, l 为层数。

$$e = \text{Avg}(e^{(1)} \parallel \dots \parallel e^{(l)}) \quad (4-7)$$

3. 传播规则的矩阵形式

为有效地更新所有用户和项目的表示, 以分块矩阵形式来传播, 具体如公式4-8所示。

$$e^{(l)} = \sigma((M + I)e^{(l-1)}W_1 + Me^{(l-1)} \odot e^{(l-1)}W_2) \quad (4-8)$$

其中, $M \in \mathbb{R}^{(m+n+p) \times (m+n+p)}$ 表示 CDS 图的拉普拉斯矩阵, $I \in \mathbb{R}^{(m+n+p) \times (m+n+p)}$ 为其同维的单位矩阵, 拉普拉斯矩阵详细定义如公式 4-9 所示。

$$M = \begin{bmatrix} 0 & R_{X_i U} & 0 \\ R_{U X_i} & R_{U U} & R_{U Y_j} \\ 0 & R_{Y_j U} & 0 \end{bmatrix} \quad (4-9)$$

其中, $R_{X_i U} \in \mathbb{R}^{m \times p}$ 和 $R_{Y_j U} \in \mathbb{R}^{n \times p}$ 分别为 X 域和 Y 域中用户邻居到目标项的权重矩阵。 $R_{U X_i} \in \mathbb{R}^{p \times m}$ 和 $R_{U Y_j} \in \mathbb{R}^{p \times n}$ 分别为两个不同的权重矩阵, 包含从两个域中的项目邻居到用户节点的权重。 $R_{U U} \in \mathbb{R}^{p \times p}$ 表示从用户节点到其相邻节点的权重矩阵, p 为位置信息。

4.2.2 图嵌入聚合

为更好地结合跨域信息，将跨域全局图和用户序列图的同一项的嵌入连接起来，将其输入到多层感知机（Multilayer Perceptron, MLP）^[66]中，获得相应的权重。

$$g^X = \text{sigmoid} \left([H^X, e_X] W_g^X + b_g^X \right) \quad (4-10)$$

本文使用 **sigmoid** 作为激活函数，使 g^X 限制在 $(0, 1)$ 内，作为用户序列图项目嵌入和跨域全局图项目嵌入的权重参数。以 X 领域的聚合图嵌入为例，由 3.2.3 节用户图嵌入 H^X 和跨域全局图嵌入 e_X 进行加权求和得到用户聚合图嵌入，如公式4-11所示。

$$H^X = g^X \cdot H^X + (1 - g^X) \cdot e_X \quad (4-11)$$

类似的方式可以计算 Y 域的聚合图嵌入。

4.2.3 模型整体架构

ATAGNN 在 TAGNN 模型基础上，为区分跨域序列图中不同领域的项目对用户选择目标领域项目偏好的影响，融合层级注意力图卷积网络从节点级和领域级估计项目节点的重要性，学习跨域序列的项目特征。




图 4-4 ATAGNN 模型的整体框架图

如图4-4所示，ATAGNN 结构由输入与嵌入层、图特征学习部分、图嵌入聚合、序列表示模块以及对比学习输出部分组成。结合不同领域中用户的交互序列数据，将其分为用户在单域的序列图 and 跨域的全局图，用户序列图包含单个用户行为序列的动态序列信息，跨域全局图包含跨序列、跨域的静态协同信息。采用门控图神经网络作为单域序列图的编码器来更新项目嵌入，捕捉用户-项目间复杂的交互模式和依赖关系。全局图

利用 HAGCN 学习来自不同领域的项目之间的协作信息,在图构造中,不同领域的项目节点通过用户节点进行关联,在消息传递过程中,通过设计的层级注意机制从节点级和领域级挖掘用户对不同领域项目的偏好关系,丰富节点的表示。为共同学习不同图中的互补信息,聚合用户序列图和跨域全局图中学习到的项目表示,并将得到的聚合表示和跨域全局图项目嵌入通过 TiAttEncoder 得到目标域和跨域中的用户顺序偏好。最后,引入对比学习辅助任务来结合用户的单域和跨域表示,通过最大化单域和跨域项目表示的交互信息增强其相关性,使用 softmax 函数预测下一个项目选择的概率。输入与嵌入层在 3.2.2 节中已经介绍,用户序列图项目特征学习已在 3.2.3 节中介绍,跨域全局图的层级注意力图卷积网络在本章 4.2.1 已经详细介绍,图聚合部分在 4.2.2 节中已经介绍,时间间隔注意力编码器 and 对比学习辅助任务以及输出部分在 3.2.5、3.2.6 小节中已经介绍。算法2中对 ATAGNN 模型整个过程进行了总结。

Algorithm 2 ATAGNN 整体推荐算法

输入:

用户在不同领域交互序列 S_X 、 S_Y , 构建混合序列 S , 网络层数 L

输出:

预测函数 $f_X(S_X, S_Y)$ 、 $f_Y(S_Y, S_X)$

- 1: 初始化嵌入 E^X 、 E^Y 、 E^G , 用户序列图 G_X 、 G_Y , 跨域全局图 G
 - 2: **while** ATAGNN 没有达到停止准则 **do**
 - 3: **for** $l = 1, 2, \dots, L$ **do**
 - 4: $h_l^{S,X} = GGNN(G_X, E^X)$ 、 $h_l^{S,Y} = GGNN(G_Y, E^Y)$
 - 5: $e_X^{(l)} = \sum_{i \in S_X} (\sum_{k \in U} m_{k \rightarrow i}^{(l)})$, $e_Y^{(l)} = \sum_{j \in S_Y} (\sum_{k \in U} m_{k \rightarrow j}^{(l)})$
 - 6: **end for**
 - 7: 获得用户域内项目表征
 - 8: $H^X = Mean(\{h_1^{S,X}, h_2^{S,X}, \dots, h_l^{S,X}\})$
 - 9: $H^Y = Mean(\{h_1^{S,Y}, h_2^{S,Y}, \dots, h_l^{S,Y}\})$
 - 10: 获得域间项目表征 $e = Avg(\{e^1, e^2, \dots, e^l\})$
 - 11: 聚合图嵌入 $H^X \leftarrow (H^X, e_X)$ 、 $H^Y \leftarrow (H^Y, e_Y)$
 - 12: 序列表示输出
 - $H_X \leftarrow TiAttEncoder(H^X, E^X)$
 - $H_Y \leftarrow TiAttEncoder(H^Y, E^Y)$
 - $H \leftarrow TiAttEncoder(e, E^G)$
 - 13: 算法 1 优化 $\leftarrow$ return H_X, H_Y, H
 - 14: **end while**
 - 15: 得到预测函数 f_X, f_Y
-

4.3 模型性能验证

4.3.1 实验环境与设置

实验用在 AutoDL 租用的 RTX 3090 服务器对数据集进行训练, 主要使用 PyTorch 框架实现 ATAGNN 模型, 实验数据集与第三章实验数据集相同, 采用公开数据集 Amazon (亚马逊) 对该模型进行对比验证, 选择四个领域生成两组跨域序列推荐场景进行实验: 亚马逊中 “Movie-Book” 和 “Food-Kitchen” 进行实验。为更好地对比模型性能的提升, 采用相同的训练集、测试集和验证集。同时对比基线也与第三章一致, 参数设置为: 嵌入层中的 Embedding 向量维度设置为 64, 将 batchsize 设为 256, 学习率设置为 0.005, dropout 比率为 0.1, 图神经网络层数为 3, 采用 Adam 作为优化算法, 最后的预测节点采用 softmax 作为激活函数。

4.3.2 模型性能对比

表4-1、表4-2展示了所有对比的模型与本章所提出 ATAGNN 模型在两组数据集中的实验结果。从表中可以直观看到 ATAGNN 模型的 HR 和 NDCG 指标均对比模型取得了明显的提升, 经过分析得出以下结论。

表 4-1 不同模型在 Movie-Book 数据集上的性能对比

模型	Movie		Book	
	NDCG@10	HR@10	NDCG@10	HR@10
BPR-MF	0.0280	0.0495	0.0117	0.0215
GRU4Rec	0.0363	0.0545	0.0156	0.0237
TiSASRec	0.0372	0.0563	0.0171	0.0281
SR-GNN	0.0378	0.0581	0.0166	0.0272
NCF-MLP	0.0286	0.0525	0.0122	0.0223
CoNet	0.0321	0.0536	0.0128	0.0231
π -Net	0.0417	0.0611	0.0203	0.0284
MIFN	0.0525	0.0833	0.0232	0.0317
C ² DSR	0.0575	0.0955	0.0245	0.0375
LEA-GCN	0.0619	0.1066	0.0274	0.0435
ATAGNN	0.0792	0.1302	0.0408	0.0605

ATAGNN 在 Movie-Book 数据集和 Food-Kitchen 数据集上的 HR@10 和 NDCG@10 上的实验结果都优于其它对比模型, 展示了 ATAGNN 模型在解决跨域序列任务上的有效性。说明 ATAGNN 中的层级注意力图卷积网络有选择地聚合领域项目节点信息, 不仅可以学习到领域内项目信息, 还可以学习到领域间结构信息和序列信息, 同时 ATAGNN 基于 TAGNN 模型有能力捕获用户行为序列和时间间隔信息。此外, ATAGNN 通过结合

用户跨域行为模式在四个领域上都取得了最好的性能，表明了考虑跨域信息的好处，证明了其在结合跨域行为模式方面的能力。

表 4-2 不同模型在 Food-Kitchen 数据集上的性能对比

模型	Food		Kitchen	
	NDCG@10	HR@10	NDCG@10	HR@10
BPR-MF	0.0413	0.0592	0.0169	0.0305
GRU4Rec	0.0612	0.0911	0.0310	0.0522
TiSASRec	0.0824	0.1214	0.0409	0.0664
SR-GNN	0.0835	0.1227	0.0413	0.0684
NCF-MLP	0.0431	0.0686	0.0203	0.0365
CoNet	0.0424	0.0735	0.0261	0.0471
π -Net	0.0860	0.1175	0.0373	0.0667
MIFN	0.0901	0.1271	0.0429	0.0708
C ² DSR	0.0962	0.1419	0.0486	0.0809
LEA-GCN	0.1001	0.1493	0.0524	0.0882
ATAGNN	0.1134	0.1705	0.0631	0.1004

ATAGNN 展现了在跨领域推荐结合用户混合行为，利用跨领域信息的显著优势，超越了序列推荐方法（GRU4Rec、TiSASRec、SR-GNN）。相比于基于 RNN 的跨域序列推荐方法 π -Net，ATAGNN 通过多角度地建模序列信息并使用 GCN 技术精细地捕捉用户与项目间的互动，证明了其有效性。这不仅表现出采用图结构模型在融合跨域特征上的强大能力，也表明基于图的跨域序列推荐方法（如 MIFN、C²DSR）在忽略用户行为模式时的局限性，强调了综合考虑用户行为模式的重要性。

在两组数据集中，Movie 数据集获得了更显著的改进，可能是由于它与 Book 领域的关系更紧密，即用户在 Book 领域的交互序列更能影响其在 Movie 领域的下一次交互，另一个可能的原因是 Movie 数据集项目记录较少，因此从另一个领域项目行为模式转移知识可能更有帮助。

4.3.3 消融实验

在 4.3.2 的对比实验中，验证了本文提出的 ATAGNN 模型是有效的，但却没有针对 ATAGNN 模型取得的效果给出合理的解释。为了更准确合理地比较模型的有效性，本节对模型结构进行了消融实验。

TAGNN：为第三章提出的基于时间感知的图神经网络跨域推荐模型，即结合用户在不同领域中的序列进行建模，从用户序列图中捕获用户动态兴趣变化，跨域全局图捕获用户的多域的行为模式以及协作信号，同时使用时间间隔注意力编码器获取用户序列表示。

$w/o-G_N$: 表示在 ATAGNN 模型中, 去除领域级注意力, 仅使用 HAGCN 中的节点级注意力机制捕获跨域全局图中项目行为模式。

$w/o-G_D$: 表示在 ATAGNN 模型中, 去除节点级注意力, 仅使用 HAGCN 中的领域级注意力机制捕获跨域全局图中项目行为模式。

表 4-3 消融实验在 Movie-Book 上性能对比

模型	Movie		Book	
	NDCG@10	HR@10	NDCG@10	HR@10
TAGNN	0.0733	0.1235	0.0328	0.0521
$w/o-G_N$	0.0756	0.1262	0.0360	0.0555
$w/o-G_D$	0.0780	0.1289	0.0384	0.0571
ATAGNN	0.0792	0.1302	0.0408	0.0605

表 4-4 消融实验在 Food-Kitchen 上性能对比

模型	Food		Kitchen	
	NDCG@10	HR@10	NDCG@10	HR@10
TAGNN	0.1079	0.1609	0.0575	0.0933
$w/o-G_N$	0.1092	0.1645	0.0596	0.0953
$w/o-G_D$	0.1115	0.1670	0.0613	0.0985
ATAGNN	0.1134	0.1705	0.0631	0.1004

表4-3、表4-4展示了消融模型在 HR 和 NDCG 两个指标上的实验结果。通过实验结果的对比, 从整体来看加入不同级别注意力机制对推荐性能都有所提升, 同时使用节点级注意力和领域级注意力时性能最好。在两组数据集上, $w/o-G_N$ 和 $w/o-G_D$ 比第三章 TAGNN 模型在 HR 和 NDCG 指标上均有提升, 证明在图卷积网络中区分邻居节点的影响的重要性对模型的训练起到正向作用。 $w/o-G_D$ 的效果优于 $w/o-G_N$, 表明了不同领域对用户偏好的影响大于不同项目对用户偏好的影响, 也证明了使用跨域信息的有效性。所提出的 ATAGNN 模型相比于 TAGNN 在 Food-Kitchen 场景下的 Food 数据集上 NDCG 和 HR 分别提升了 0.55%、0.96%, Kitchen 数据集上 NDCG 和 HR 分别提升了 0.56%、0.71%, 在 Movie-Book 场景下 Movie 数据集上 NDCG 和 HR 分别提升了 0.59%、0.67%, 在 Book 数据集上 NDCG 和 HR 分别提升了 0.8%、0.84%。以上结果说明在基于图神经网络的跨域推荐中引入层级注意力机制可以有效地捕捉用户的偏好, 有利于提高推荐的性能。

通过对比第三章 TAGNN 模型和第四章 ATAGNN 模型的 HR 与 NDCG 指标, 可以发现模型性能得到了较大的提升。在跨域全局图消息传递的过程中加入了层级注意力机制, 尽管模型的复杂度增加了, 但实验结果并没有出现过拟合的问题。实验对比结果显示, 本文提出的 ATAGNN 模型展现出了一定的优越性。

4.3.4 超参数学习

(1) 序列长度影响

为了分析不同序列长度对模型性能的影响进行探究。在保持其它超参数不变的情况下，图4-5显示了将 Movie-Book 数据集和 Food-Kitchen 数据集序列长度从 10 到 50 划分的验证结果。大多数用户交互数据的序列长度在领域中是稀疏的。ATAGNN 在短序列，在所有数据集上都有较大的提升，原因是较短的序列长度表明用户的交互数据更稀疏，传统的单域推荐方法难以捕获用户的偏好。相比之下，引入用户相关领域的行为模式可以增强学习用户的偏好，在这种情况下跨域知识转移更加有效，ATAGNN 在大多数序列长度上取得了较好的性能，这也就证明了 ATAGNN 在顺序推荐方面的优越性。




图 4-5 不同最大序列长度的 ATAGNN 性能

(2) 嵌入维度影响

此外，本文还研究了嵌入维度的影响，即用户-项目表示的维度，在 {16, 32, 48, 64, 80, 96} 范围内通过改变嵌入大小进行实验。在 Food-Kitchen 数据集上的实验结果如图4-6所示。




图 4-6 不同嵌入维度的 ATAGNN 性能

从图中可以看出,当嵌入维度为 16 时会严重限制模型的表征能力,从而导致次优的推荐性能。然而,随着嵌入维度适度增加到 32 时,在 Food 数据集上 NDCG 指标显著提升了约 1.61%,HR 指标显著提升约 1.84%。超过 64 后,性能增益逐渐趋于平稳,这表明适当的嵌入维度可为项目提供更准确的嵌入,从而丰富用户偏好的表示。值得注意的是,当嵌入维度超过 80 时,模型的性能出现停滞或退化。这可能是因为过大的嵌入维度会导致模型出现过拟合,还会造成计算资源的增加以及模型运行的时间过长。因此,在模型性能和资源利用之间取得平衡是很重要的。通过本文的实验表明,根据数据集的大小将嵌入大小设置为 64 较为适宜。

4.4 本章小结

首先分析了现有跨域推荐模型以及第 3 章提出的 TAGNN 模型的不足之处,如未能考虑跨域全局图中不同领域项目节点的重要性。因此,在 TAGNN 模型的基础上,提出了基于注意力和时间感知的图神经网络跨域推荐模型 ATAGNN,并对层级注意力图卷积网络消息传递、聚合过程等相关信息进行详细说明。然后为更好地结合不同领域信息,聚合用户序列图和跨域全局图得到的图嵌入。最后,通过对比实验和消融实验验证了 ATAGNN 模型结构的合理性及推荐效果的优越性。

第5章 跨领域推荐系统的设计与实现

随着数字化时代的到来,应用领域数量的急剧增加使用户的在线行为变得更加多元化。然而,由于仅依靠单领域数据无法较好的为用户提供个性化推荐,为解决此问题提出跨域推荐系统。第四章跨域推荐模型(ATAGNN)是一个通用的推荐模型,本章结合电影和图书领域,基于ATAGNN设计并实现了一个交互的电影图书推荐系统,该系统可以根据用户的交互记录,结合两个领域的序列数据准确地向用户推荐个性化项目。

5.1 需求分析

电影和图书作为互联网平台上的一种娱乐形式,已经成为人们日常生活中必不可少的一部分。本章基于第四章提出的ATAGNN推荐模型,将其应用于实际,模拟豆瓣商城设计并实现了一个电影图书推荐系统,现从功能性需求和非功能性需求对此系统进行分析。

5.1.1 功能需求分析

本文的跨域推荐系统主要分为电影和图书两个模块。本系统将用户的个人信息、用户的交互数据(即评分)、电影/图书的内容信息(包括ID、标题、类型等)作为推荐系统的基础数据。接下来对电影图书推荐系统的功能需求进行分析,分别从普通用户和管理员两个角度展开描述。

(1) 普通用户

普通用户为系统的使用者,主要包括注册登录、个人信息管理、电影推荐、图书推荐、电影/图书查看、评分等功能。

注册登录:新用户进入系统时,系统无法获取到其个人信息及历史交互数据,无法对用户进行个性化推荐。因此用户首次使用时,需要设置用户名、密码等基本信息进行注册,注册完成后返回登录界面,输入用户名和密码进行登录,登录成功后将跳转到系统首页。

个人信息管理:用户可以在系统中修改密码、邮箱等信息。

电影推荐:用户进入电影页面时,跨域推荐模型将根据用户的交互历史为用户推荐相关电影并展示。新用户进入系统时,推荐当前热门电影。

图书推荐:用户进入图书页面时,跨域推荐模型将根据用户的交互历史为用户推荐相关图书并展示。新用户进入系统时,推荐当前热门图书。

电影、图书查看:用户可以点击页面对应电影、图书查看其详细信息,也可以通过搜索框进行模糊查询获取自己想要的电影或图书。

电影、图书评分:用户可以对电影、图书给出相应的评分等反馈信息。

(2) 管理员

管理员主要是负责系统的管理和维护,管理用户相关信息、电影和图书相关信息。

登录:管理员使用已有的账号和密码进行登录,登录成功后进入后台管理系统。

用户管理:管理员可以查询用户信息,对用户的账号状态进行修改。一旦用户的账号被禁用,则用户将无法再使用此账号,开启后方可正常使用。

电影管理:管理员能够对电影信息进行添加、修改、删除操作。

图书管理:管理员能够对图书信息进行添加、修改、删除操作。

5.1.2 非功能性需求分析

在系统的设计中,不仅要实现上述功能需求,还要考虑非功能性需求,主要表现在以下几个方面。

(1) 可靠性

系统需要保持稳定的运行,因此在满足功能性需求的情况下还需要在数据库设计以及业务逻辑方面进行优化设计,以保障系统的可靠性。

(2) 安全性

系统中涉及到用户的敏感信息,例如用户密码、邮箱等,对于这部分信息需要加强其安全性可以采用加密处理,实施身份验证,确保只有管理员能够访问敏感信息。另外,还要控制用户与管理器的操作权限,明确两者的界限。

(3) 可扩展性

在系统设计时,要考虑各个模块之间的耦合性,当需要增加功能时,保证新功能的集成和系统扩展不影响现有功能的性能。同时,系统要能够适应用户数量的增长,提高系统的灵活性和可扩展性。

5.2 系统设计

5.2.1 系统架构设计

本文的跨域推荐系统分为前端服务和后端服务。前端服务使用 Vue 框架,Vue 是用于构建用户界面的渐进式 JavaScript 框架^[67],其允许将网页分割成可复用的组件,每个组件包含属于自己的 HTML、CSS、JavaScript。后端主要使用简化、加快 Spring 应用程序开发的开源框架 SpringBoot,通过提供一系列开箱即用的特性,如自动配置、内嵌服务器支持以及健壮的安全性选项,极大地加快了开发流程。不仅简化了 Spring 应用程序的开发和部署过程、提供了丰富的功能和工具,还为系统的扩展、监控和安全提供了强大的支持。跨域推荐系统总体框架如图5-1所示。

Web: 提供 UI 页面,负责展示数据和接收用户的输入。该层提供了用户与系统互动所需的服务和应用。在这一层,用户能够浏览电影和书籍,并进行相应的评分。接收




图 5-1 系统整体架构图

到用户互动后，交互层通过 HTTP 连接发送数据给系统，系统的其它层处理这些数据并迅速反馈，通过 Web 与后端进行操作，展示后端处理的结果，最后形成数据可视化包含推荐结果、电影/图书详情。

服务层负责实现系统的业务逻辑，包括用户登录注册、电影/图书信息推荐、查询、评分功能，管理员对用户管理、电影/图书管理功能。

业务层负责为整个系统提供服务支持，为推荐服务请求和核心业务建立模型，包括用户服务、评分服务、推荐服务三个部分。在该层中，系统处理各项业务逻辑，将用户行为转化为数据并存储于数据库中。同时，通过调用核心算法，向用户展示推荐结果。推荐服务作为系统的核心环节，用于处理用户行为数据，并基于这些数据计算出个性化的推荐内容。

数据层主要负责为推荐系统提供数据支持，存储系统中的关键数据，确保数据的持久化，为系统提供关键服务。系统中用户的基本信息存储在 MySQL 数据库中，Redis 存储用户的 token 信息以实现未登录拦截，保持会话功能。其作为缓存为推荐系统带来了快速的数据访问能力、高度的可扩展性和灵活的数据处理能力。

5.2.2 功能模块设计

系统的基本功能主要根据 5.1 节中的需求分析来设计。系统功能架构图如图5-2所示，系统分为两部分，主要按照角色的不同将基础功能分为用户业务子系统和管理员业务子系统，功能模块介绍如下。

1、用户业务模块

登录模块：是用户访问系统的入口，负责处理用户的身份验证和授权。新用户第一次进入系统需要先注册账号才能登录进入，通过账号和密码验证用户身份。管理员根据已有账号密码登录进入后台管理系统中。




图 5-2 系统功能结构图

推荐功能：新用户按照评分和时间排序生成热门推荐列表。当用户有交互历史时，使用第四章提出的跨域推荐模型根据用户在电影、图书两个领域的交互数据计算得到个性化的推荐结果。系统推荐的工作流程如图5-3所示。




图 5-3 系统推荐流程图

新用户先注册再登录进入系统，首次进入推荐当前热门电影/图书。老用户进入系统首页向后端发送请求获取推荐电影/图书列表，系统后端接收请求后对用户使用训练好的跨域推荐模型返回用户感兴趣的电影/图书。系统后端将推荐列表缓存进 Redis 以提高响应速度，为减少前端资源开销和保证响应速度，用户每次请求从 Redis 里按顺序将电影/图书返回给用户。

评分功能：用户可以查看电影、图书详情页面并进行评分，后台系统会记录用户的评分数据并更新推荐列表。

搜索功能：利用数据库进行关键字模糊查询。

2、管理员业务模块

电影/图书管理：后台管理员对电影/图书进行更新，包括添加、删除、修改功能。

用户管理：查询用户信息、修改用户账号状态，一旦状态改为禁用用户将不能使用此账号。

5.2.3 数据库设计

在推荐算法中，所需进行计算的数据是从数据库获取的，数据库能显著降低数据检索时间，从而提升推荐系统的效率。基于前面的需求分析和功能设计得出，本文的跨域推荐系统的数据表主要从用户、电影、图书、评分数据实体关系设计，如图5-4所示，包含了各个实体的属性及其联系。




图 5-4 数据库 E-R 图

1、用户信息表

用户信息表存储用户的基本信息。主要是用户在注册账号时提交的信息，如用户 ID、用户名称、密码等信息。用户信息表如表5-1所示。

表 5-1 用户信息表

字段	字段类型	是否为主键	是否为空	字段说明
user_id	int(15)	是	否	用户 ID
user_name	varchar(255)	否	否	用户名
password	varchar(255)	否	否	用户密码
register_time	datetime	否	否	用户注册时间
email	varchar(255)	否	是	用户邮箱
status	int	否	否	账号状态

2、电影信息表

电影信息表存储电影信息，包括电影 ID、名称、类型等。电影信息表如表5-2所示。

表 5-2 电影信息表

字段	字段类型	是否为主键	是否为空	字段说明
movie_id	int(15)	是	否	电影 ID
movie_name	varchar(255)	否	否	电影名
movie_director	varchar(255)	否	否	导演
movie_actors	varchar(255)	否	否	主演
movie_release_date	datetime	否	否	上映时间
movie_type_id	int(15)	否	否	电影类型
movie_rating	double	否	否	电影评分

3、图书信息表

图书信息表存储图书信息，包括图书 ID、名称、类型等。图书信息表如表5-3所示。

表 5-3 图书信息表

字段	字段类型	是否为主键	是否为空	字段说明
book_id	int(15)	是	否	图书 ID
book_name	varchar(255)	否	否	图书名称
book_author	varchar(255)	否	否	作者
publication_date	datetime	否	否	出版时间
book_type_id	varchar(255)	否	否	图书类型
book_rating	double	否	否	图书评分

4、评分信息表

用户对电影评分信息表如5-4所示。

用户对图书评分信息表如5-5所示。

表 5-4 用户电影评分信息表

字段	字段类型	是否为主键	是否为空	字段说明
m_rating_id	int(15)	是	否	评分 ID
user_id	int(15)	否	否	用户 ID
movie_id	int(15)	否	否	电影 ID
movie_score	double	否	否	评分
m_rating_time	datetime	否	否	评分时间

表 5-5 用户图书评分信息表

字段	字段类型	是否为主键	是否为空	字段说明
b_rating_id	int(15)	是	否	评分 ID
user_id	int(15)	否	否	用户 ID
book_id	int(15)	否	否	图书 ID
book_score	double	否	否	评分
b_rating_time	datetime	否	否	评分时间

5.3 系统实现

5.3.1 开发环境

系统的开发环境如表5-6所示。开发是在 Windows 11 操作系统上完成的，IDEA 作为系统开发工具，使用 Java 语言以及 SpringBoot 框架开发后端服务，前端技术使用 Vuc 框架。跨域推荐模型是基于 Python 实现的，MySQL 作为系统的数据存储，Redis 为系统提供缓存功能。

表 5-6 系统开发环境汇总表

软硬件	详细参数
操作系统	Windows 11
开发框架	SpringBoot、Vue
数据库	MySQL、Redis
深度学习框架	Pytorch
CPU	ADM Ryzen 7 4800H

5.3.2 系统页面展示

1. 登录注册

用户进入系统登录页面时，需要在登录界面输入用户名和密码，点击登录按钮进行

验证。验证成功可进入系统首页，若是密码错误则会提示相应错误需要重新输入。如果用户是新用户，可点击“注册”将会跳转到注册页面，输入对应的信息即可完成注册，注册成功过后会自动跳转到登录页面。本文的跨域推荐系统登录注册页面如图5-5所示。



图 5-5 登录页面

2. 系统主页面

如图5-6，本系统页面菜单栏有3个选项，首页、电影和图书，用户通过点击相应的按钮可以跳转到对应的界面。系统主页面主要是向登录成功的用户展示目前热门的电影图书列表。当用户点击电影或图书按钮时，会跳转到电影或图书推荐页面，为用户展示推荐列表。另外，系统还提供了搜索功能，用户在搜索栏输入关键字可以查询想要的电影或者图书。




图 5-6 系统主页面

3. 电影推荐

图5-7为点击电影按钮后，跳转到的电影推荐界面。在该页面，系统根据用户的历史交互记录以及电影的信息为用户生成推荐内容。当用户在电影领域中的交互信息较少时，结合用户在另一个领域的交互信息来进行相关推荐。当用户为冷启动用户时，则为其推荐当前热门的电影。




图 5-7 电影推荐界面

4. 图书推荐

图5-8为点击图书按钮后，将切换到图书推荐界面。在该页面，系统根据用户的历史交互记录以及图书的信息为用户生成推荐内容。当用户在图书领域中的交互信息较少时，结合用户在另一个领域的交互信息来进行相关推荐。当用户为冷启动用户时，则为其推荐当前热门的图书。



图 5-8 图书推荐界面

5. 详情和评分页面

图5-9为详情页面，用户点击电影或图书进入其详情页查看具体信息，详情页中可以点击评分按钮进行评分。用户评分后系统将根据用户的反馈做出相应的推荐更新。



图 5-9 详情页和评分界面

6. 管理员界面

图5-10为管理员管理页面。在该页面, 管理员可对电影、图书信息进行增加、删除、修改, 以及对用户信息进行查询和修改。



图 5-10 管理员界面

5.4 系统测试

系统测试是根据需求分析验证功能实现和检测缺陷的步骤。常用方法包括黑盒测试、白盒测试和灰盒测试。黑盒测试侧重于通过系统功能页面进行功能检测, 无需了解具体代码如何实现的。白盒测试则根据代码情况编写测试用例, 测试系统功能的边界情况。灰盒测试介于两者之间, 对代码的了解不需太深入, 主要基于接口测试, 验证接口

的输入输出即可。

本文主要通过黑盒测试方法来进行功能验证，基于需求规格说明来检验功能是否按预期实现。另外，在开发阶段，采用白盒测试策略，利用各种测试场景来评估代码逻辑的正确性。

5.4.1 功能性测试

功能测试包括用户登录、电影/图书推荐和用户评分三个主要功能的测试。
登录功能测试如表5-7所示。

表 5-7 登录功能测试用例表

用例编号	测试用例	预期结果	测试结果
1	输入正确的用户名密码	登录成功并进入首页	与预期一致
2	输入已有账号，但密码错误	提示密码错误	与预期一致
3	只输入用户名或密码点击登录	提示登录信息未填写完	与预期一致
4	密码输入不合法字符如 * () 或超过长度限制	提示登录信息有不合法字符或长度超过 18 位	与预期一致
5	输入未注册的用户名	提示用户名不存在	与预期一致
6	未登录进入首页	重定向到登录页面	与预期一致
7	登录成功后，点击退出登录	退出用户账号，跳转到登录页面	与预期一致

推荐功能测试如表5-8所示。

表 5-8 推荐功能测试用例表

用例编号	测试用例	预期结果	测试结果
1	新用户进入系统首页	推荐高分电影、图书	与预期一致
2	浏览电影推荐列表	展示对应电影	与预期一致
3	浏览图书推荐列表	展示对应图书	与预期一致
4	电影推荐结果更新	用户对图书评分后，进入电影页面，展示更新后的推荐列表	与预期一致
5	图书推荐结果更新	用户对电影评分后，进入图书页面，展示更新后的推荐列表	与预期一致
6	搜索框输入正确的电影/图书	展示搜索结果	与预期一致
7	搜索框输入不存在的电影/图书	搜索列表显示为空	与预期一致
8	点击电影/图书封面或名称	跳转到电影/图书详情	与预期一致

评分功能测试如表5-9所示。

表 5-9 评分功能测试用例表

用例编号	测试用例	预期结果	测试结果
1	进入任一电影详情, 输入对其评分	弹出正确提示	与预期一致
2	进入任一图书详情, 输入对其评分	弹出正确提示	与预期一致

5.4.2 性能测试

本节主要针对系统实现的主要模块进行性能测试, 观察核心功能的耗时情况。针对耗时较高的接口分析原因并提出解决方案。

表 5-10 主要功能模块测试结果表

测试编号	测试用例	允许平均最大耗时 (s)	耗时 (s)
1	启动系统	2	0.44
2	登录	2	0.52
3	注册	2	0.42
4	评分	2	0.45
5	搜索物品	2	0.63

表5-10可以看出, 测试的主要业务功能模块均在预期范围内。接下来针对模型的响应时间进行测试, 确定其对用户体验所造成的影响, 如表5-11所示。

表 5-11 响应时间测试结果表

测试编号	测试用例	允许最大平均耗时 (s)	耗时 (s)
1	进入电影页面, 显示推荐列表	2	0.85
2	进入图书页面, 显示推荐列表	2	0.82
3	与电影交互后返 回首页	2	0.56
4	与图书交互后返 回首页	2	0.59

推荐模块的响应时间在各种场景下都在预期时间内。由于电影商品数量较多, 电影领域的整体响应时间相比图书领域较长。值得注意的是, 进入首页推荐与进行交互后返回首页推荐的响应时间是不同的, 后者需要重新计算近期的交互序列, 因此其耗时更长。

5.5 本章小结

本章实现了一个基于 ATAGNN 模型的电影图书推荐系统。首先对整个系统进行了需求分析, 根据需求分析设计系统的总体架构、功能模块以及数据库表设计。接着介绍系统的开发环境, 展示了系统的主要功能界面。最后为了确保系统功能满足需求, 对整个系统做了较为全面的功能与性能测试。

第6章 总结与展望

本章将对全文工作进行总结, 并对该研究方向的未来工作进行展望。

6.1 全文总结

随着数字化时代的到来, 应用平台数量的急剧增加使用户的在线行为变得更加多元化。从社交媒体、电子商务到在线教育和娱乐, 人们在日常生活的各个领域内寻找信息、进行交互和完成交易。这种跨域的用户行为激增, 为推荐系统提出了新的挑战和机遇。传统的推荐系统往往局限于单一领域, 例如仅在电商平台上推荐商品或在社交媒体上推荐内容, 难以全面理解和满足用户的复杂需求, 且存在数据稀疏性和冷启动问题。随着跨域推荐系统的兴起, 通过综合分析用户在多个领域内的行为序列, 结合跨域的行为模式和偏好, 为用户提供更加个性化和精准的推荐。然而, 现有的跨域序列推荐方法仍然存在一些不足, 如忽略领域序列项目转换模式、忽视项目时间间隔信息、未考虑领域节点的重要性等。本文的主要研究工作可归纳如下:

(1) 提出了基于时间感知的图神经网络跨域推荐 (TAGNN) 模型, 解决现有跨域序列推荐未考虑领域项目转换模式以及交互时间间隔问题。模型首先将用户在不同领域的交互序列按照时间顺序构建跨域序列, 分别构建用户序列图和跨域全局图, 采用门控图神经网络 (GGNN) 作为用户序列图编码器来提取用户动态序列信息。利用图卷积网络学习跨域全局图中领域间的项目协作信息。其次, 为考虑项目时间间隔信息并增强序列的表征学习, 提出了时间间隔注意力编码器 (TiAttEncoder), 将时间间隔信息融入注意力模块中学习项目的交互特征。然后, 为了权衡跨域序列中项目对目标域的重要性, 提出了基于对比学习的辅助任务。具体的, 利用 softmax 函数计算跨域序列中源域项目对目标域的相关性, 相关性小于 0.5 的项目用掩码替换, 经过替换后得到对比序列, 将目标域序列与对比序列进行对比学习, 通过最大化域内和跨域序列表示来增强它们之间的相关性。最后, 联合域内推荐、跨域推荐任务以及辅助任务对模型进行优化。

(2) 针对基于图卷积的跨域推荐忽略了领域节点重要性的问题, 提出了基于注意力和时间感知的图神经网络跨域推荐 (Attention and Time-Aware Graph Neural Network for Cross-Domain Recommendation, ATAGNN) 模型。在跨域全局图中, 为区分不同领域项目对用户偏好的影响, 提出层级注意力图卷积网络 (Graph Convolutional Networks with Hierarchical Attention, HAGCN), 通过层级注意力从节点级和领域级自动区分领域间项目节点的重要性, 以学习项目嵌入。为更好地结合跨域信息, 将用户序列图和跨域全局图学习到的图嵌入进行聚合, 并将得到的聚合嵌入和跨域图嵌入通过序列编码器得到目标域和跨域中的用户顺序偏好。

(3) 通过在 Movie-Book 和 Food-Kitchen 两个场景数据集对 TAGNN 和 ATAGNN 模

型进行了大量的对比实验。在实验的过程中,并详细分析和讨论了实验过程和实验结果,且将其与对比模型进行详细的比较。实验结果表明,相比基线模型,本文提出的模型在 HR 和 NDCG 两个指标上都有较大幅度的提升,具有更好的推荐性能,同时也证明了它们的有效性和优越性。

(4) 开发了一个基于 ATAGNN 模型的电影图书推荐系统,该系统实现了用户对电影、图书网站的基本需求,包括搜索、推荐、评分等功能,且能够根据用户在两个领域的历史交互数据,为用户推荐感兴趣的电影或图书,并可依据用户的反馈信息进行调整和优化,从而不断地提升推荐效果。

6.2 未来研究展望

本文在跨域序列推荐问题上通过引入图神经网络技术,增强了推荐算法对用户在不同领域交互行为的理解,从而提高了跨域推荐的准确性和有效性。通过一系列的实验和测试,验证了所提出的跨域推荐模型在现实世界数据集上的表现,证明了模型的有效性。但所提出的模型仍然存在一定的局限性,需要进一步的优化,后续工作中将在以下方向加以完善:

(1) 本文工作仅考虑了用户的行为序列,将用户 ID 和项目 ID 作为主要特征,忽略了其它的元数据特征,如用户的个人信息(如年龄、性别等)、项目的辅助信息(如标签、图像等)以及用户的社交网络信息等,这些在推荐系统中同样都扮演着重要角色。未来的工作将致力于融合这些属性信息,通过设计更加复杂和精细的特征工程方法,为用户提供更加个性化的推荐服务。例如,利用用户的个人信息可能会增强模型对用户偏好的理解,而项目的图像和标签可以用于增强内容的描述,两者结合可以有效提升推荐质量。

(2) 本文的模型主要建立在两个领域上,现实世界中的用户通常会在多个领域进行交互,而不仅限于两个领域。因此,未来的研究需要将模型扩展到更多领域场景,探讨如何高效整合来自多个领域的的数据,以便构建一个更加全面的用户画像。这可能需要开发新的算法,以处理大量的领域并保持各领域性能的均衡。此外,跨域推荐系统需要能够灵活地适应新领域的加入,以及现有领域内动态变化的用户行为模式。

(3) 此外,数据的隐私和安全性是构建跨域推荐系统时不可忽视的问题。尤其是在多领域环境下,用户的数据量更大,敏感信息的保护尤为关键。未来的工作将探索如何在保障用户数据安全的同时,减少对推荐效果的影响。例如,可以研究差分隐私和同态加密等技术,以确保用户信息在推荐过程中不会被泄露,同时也允许推荐系统学习到足够的信息以提供准确的推荐。

参考文献

- [1] 陈旭松. 基于用户行为序列建模的推荐算法研究[D]. 中国科学技术大学, 2021.
- [2] Zang T, Zhu Y, Liu H, et al. A survey on cross-domain recommendation: taxonomies, methods, and future directions[J]. *ACM Transactions on Information Systems*, 2022, 41(2): 1-39.
- [3] Wang P, Guo J, Lan Y, et al. Learning hierarchical representation model for nextbasket recommendation[C]. in: *Proceedings of the 38th International ACM SIGIR conference on Research and Development in Information Retrieval*. 2015: 403-412.
- [4] Shani G, Heckerman D, Brafman R I, et al. An MDP-based recommender system[J]. *Journal of Machine Learning Research*, 2005, 6(9).
- [5] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing personalized markov chains for next-basket recommendation[C]. in: *Proceedings of the 19th international conference on World wide web*. 2010: 811-820.
- [6] Rendle S, Freudenthaler C, Gantner Z, et al. BPR: Bayesian personalized ranking from implicit feedback[J]. *arXiv preprint arXiv:1205.2618*, 2012.
- [7] He R, Fang C, Wang Z, et al. Vista: A visually, socially, and temporally-aware model for artistic recommendation[C]. in: *Proceedings of the 10th ACM conference on recommender systems*. 2016: 309-316.
- [8] Eskandarian F, Mobasher B. Modeling the dynamics of user preferences for sequence-aware recommendation using hidden Markov models[C]. in: *The Thirty-Second International Flairs Conference*. 2019.
- [9] Fang H, Zhang D, Shu Y, et al. Deep learning for sequential recommendation: Algorithms, influential factors, and evaluations[J]. *ACM Transactions on Information Systems (TOIS)*, 2020, 39(1): 1-42.
- [10] Wang S, Zhang Q, Hu L, et al. Sequential/session-based recommendations: Challenges, approaches, applications and opportunities[C]. in: *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*. 2022: 3425-3428.
- [11] Quadrana M, Karatzoglou A, Hidasi B, et al. Personalizing session-based recommendations with hierarchical recurrent neural networks[C]. in: *proceedings of the Eleventh ACM Conference on Recommender Systems*. 2017: 130-137.

- [12] Donkers T, Loepp B, Ziegler J. Sequential user-based recurrent neural network recommendations[C]. in: Proceedings of the eleventh ACM conference on recommender systems. 2017: 152-160.
- [13] Li J, Ren P, Chen Z, et al. Neural attentive session-based recommendation[C]. in: Proceedings of the 2017 ACM on Conference on Information and Knowledge Management. 2017: 1419-1428.
- [14] Liu Q, Zeng Y, Mokhosi R, et al. STAMP: short-term attention/memory priority model for session-based recommendation[C]. in: Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining. 2018: 1831-1839.
- [15] Zhou G, Mou N, Fan Y, et al. Deep interest evolution network for click-through rate prediction[C]. in: Proceedings of the AAAI conference on artificial intelligence: vol. 33: 01. 2019: 5941-5948.
- [16] Feng Y, Lv F, Shen W, et al. Deep session interest network for click-through rate prediction[J]. arXiv preprint arXiv:1905.06482, 2019.
- [17] Huang Z, Xu W, Yu K. Bidirectional LSTM-CRF models for sequence tagging[J]. arXiv preprint arXiv:1508.01991, 2015.
- [18] Tang J, Wang K. Personalized top-n sequential recommendation via convolutional sequence embedding[C]. in: Proceedings of the eleventh ACM international conference on web search and data mining. 2018: 565-573.
- [19] Li B, Yang Q, Xue X. Can movies and books collaborate? cross-domain collaborative filtering for sparsity reduction[C]. in: Twenty-First international joint conference on artificial intelligence. 2009.
- [20] Berkovsky S, Kuflik T, Ricci F. Cross-domain mediation in collaborative filtering[C]. in: User Modeling 2007: 11th International Conference, UM 2007, Corfu, Greece, July 25-29, 2007. Proceedings 11. 2007: 355-359.
- [21] Cao D, He X, Nie L, et al. Cross-platform app recommendation by jointly modeling ratings and texts[J]. ACM Transactions on Information Systems (TOIS), 2017, 35(4): 1-27.
- [22] Jiang M, Cui P, Yuan N J, et al. Little is much: Bridging cross-platform behaviors through overlapped crowds[C]. in: Proceedings of the AAAI Conference on Artificial Intelligence: vol. 30: 1. 2016.
- [23] Elkahky A M, Song Y, He X. A multi-view deep learning approach for cross domain user modeling in recommendation systems[C]. in: Proceedings of the 24th international conference on world wide web. 2015: 278-288.

- [24] Man T, Shen H, Jin X, et al. Cross-domain recommendation: An embedding and mapping approach[C]. in: IJCAI: vol. 17. 2017: 2464-2470.
- [25] Hu G, Zhang Y, Yang Q. Conet: Collaborative cross networks for cross-domain recommendation[C]. in: Proceedings of the 27th ACM international conference on information and knowledge management. 2018: 667-676.
- [26] Zhu F, Wang Y, Zhou J, et al. A unified framework for cross-domain and cross-system recommendations[J]. IEEE Transactions on Knowledge and Data Engineering, 2021.
- [27] Wang Y, Feng C, Guo C, et al. Solving the sparsity problem in recommendations via cross-domain item embedding based on co-clustering[C]. in: Proceedings of the Twelfth ACM International Conference on Web Search and Data Mining. 2019: 717-725.
- [28] Ma M, Ren P, Lin Y, et al. π -net: A parallel information-sharing network for shared-account cross-domain sequential recommendations[C]. in: Proceedings of the 42nd international ACM SIGIR conference on research and development in information retrieval. 2019: 685-694.
- [29] Li P, Jiang Z, Que M, et al. Dual attentive sequential learning for cross-domain click-through rate prediction[C]. in: Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining. 2021: 3172-3180.
- [30] Wu S, Tang Y, Zhu Y, et al. Session-based recommendation with graph neural networks [C]. in: Proceedings of the AAAI conference on artificial intelligence: vol. 33: 01. 2019: 346-353.
- [31] Qiu R, Li J, Huang Z, et al. Rethinking the item order in session-based recommendation with graph neural networks[C]. in: Proceedings of the 28th ACM international conference on information and knowledge management. 2019: 579-588.
- [32] Wang Z, Wei W, Cong G, et al. Global context enhanced graph neural networks for session-based recommendation[C]. in: Proceedings of the 43rd international ACM SIGIR conference on research and development in information retrieval. 2020: 169-178.
- [33] Zhao C, Li C, Fu C. Cross-domain recommendation via preference propagation graph-net[C]. in: Proceedings of the 28th ACM international conference on information and knowledge management. 2019: 2165-2168.
- [34] Liu M, Li J, Li G, et al. Cross domain recommendation via bi-directional transfer graph collaborative filtering networks[C]. in: Proceedings of the 29th ACM international conference on information & knowledge management. 2020: 885-894.
- [35] Xi D, Zhuang F, Zhu Y, et al. Graph factorization machines for cross-domain recommendation[J]. arXiv preprint arXiv:2007.05911, 2020.

- [36] Zhu F, Wang Y, Chen C, et al. A graphical and attentional framework for dual-target cross-domain recommendation[C]. in: IJCAI. 2020: 3001-3008.
- [37] Grover A, Leskovec J. node2vec: Scalable feature learning for networks[C]. in: Proceedings of the 22nd ACM SIGKDD international conference on Knowledge discovery and data mining. 2016: 855-864.
- [38] Cui Q, Wei T, Zhang Y, et al. HeroGRAPH: A Heterogeneous Graph Framework for Multi-Target Cross-Domain Recommendation[C]. in: ORSUM@ RecSys. 2020.
- [39] Ma M, Ren P, Chen Z, et al. Mixed information flow for cross-domain sequential recommendations[J]. ACM Transactions on Knowledge Discovery from Data (TKDD), 2022, 16(4): 1-32.
- [40] Guo L, Tang L, Chen T, et al. DA-GCN: a domain-aware attentive graph convolution network for shared-account cross-domain sequential recommendation[C]. in: IJCAI International Joint Conference on Artificial Intelligence. 2021: 2483-2489.
- [41] Guo L, Zhang J, Tang L, et al. Time interval-enhanced graph neural network for shared-account cross-domain sequential recommendation[J]. IEEE Transactions on Neural Networks and Learning Systems, 2022.
- [42] Zheng X, Su J, Liu W, et al. DDGHM: dual dynamic graph with hybrid metric training for cross-domain sequential recommendation[C]. in: Proceedings of the 30th ACM International Conference on Multimedia. 2022: 471-481.
- [43] Li C, Zhao M, Zhang H, et al. RecGURU: Adversarial learning of generalized user representations for cross-domain recommendation[C]. in: Proceedings of the fifteenth ACM international conference on web search and data mining. 2022: 571-581.
- [44] Gao S, Luo H, Chen D, et al. A cross-domain recommendation model for cyber-physical systems[J]. IEEE Transactions on Emerging Topics in Computing, 2013, 1(2): 384-393.
- [45] Zhu F, Wang Y, Chen C, et al. Cross-domain recommendation: challenges, progress, and prospects[C]. in: 30th International Joint Conference on Artificial Intelligence, IJCAI 2021. 2021: 4721-4728.
- [46] 童小凯, 朱欣娟, 王西汉, 等. 数字文化资源知识图谱多目标跨域推荐方法[J]. 计算机工程与应用, 2023, 59: 142-150.
- [47] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [48] Zhou J, Cui G, Hu S, et al. Graph neural networks: A review of methods and applications [J]. AI open, 2020, 1: 57-81.

- [49] 刘杰. 基于图神经网络的序列推荐算法研究与应用[D]. 南昌大学, 2023.
- [50] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks [J]. arXiv preprint arXiv:1609.02907, 2016.
- [51] Velickovic P, Cucurull G, Casanova A, et al. Graph attention networks[J]. stat, 2017, 1050(20): 10-48550.
- [52] Li Y, Tarlow D, Brockschmidt M, et al. Gated graph sequence neural networks[J]. arXiv preprint arXiv:1511.05493, 2015.
- [53] Yu J, Yin H, Xia X, et al. Self-supervised learning for recommender systems: a survey [J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(1): 335-355.
- [54] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. in: Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [55] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.
- [56] 田娟, 李英祥, 李彤岩. 激活函数在卷积神经网络中的对比研究[J]. 计算机系统应用, 2018, 27: 43-49.
- [57] Oord A v d, Li Y, Vinyals O. Representation learning with contrastive predictive coding [J]. arXiv preprint arXiv:1807.03748, 2018.
- [58] Cao J, Cong X, Sheng J, et al. Contrastive Cross-Domain Sequential Recommendation [C]. in: Proceedings of the 31st ACM International Conference on Information & Knowledge Management. 2022: 138-147.
- [59] Wang X, He X, Wang M, et al. Neural graph collaborative filtering[C]. in: Proceedings of the 42nd international ACM SIGIR conference on Research and development in Information Retrieval. 2019: 165-174.
- [60] Glorot X, Bengio Y. Understanding the difficulty of training deep feedforward neural networks[C]. in: Proceedings of the thirteenth international conference on artificial intelligence and statistics. 2010: 249-256.
- [61] Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [62] Hidasi B, Karatzoglou A, Baltrunas L, et al. Session-based recommendations with recurrent neural networks[J]. arXiv preprint arXiv:1511.06939, 2015.

- [63] Li J, Wang Y, McAuley J. Time interval aware self-attention for sequential recommendation[C]. in: Proceedings of the 13th international conference on web search and data mining. 2020: 322-330.
- [64] He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]. in: Proceedings of the 26th international conference on world wide web. 2017: 173-182.
- [65] Zhang J, Duan H, Guo L, et al. Towards lightweight cross-domain sequential recommendation via external attention-enhanced graph convolution network[C]. in: International Conference on Database Systems for Advanced Applications. 2023: 205-220.
- [66] Popescu M C, Balas V E, Perescu-Popescu L, et al. Multilayer perceptron and neural networks[J]. WSEAS Transactions on Circuits and Systems, 2009, 8(7): 579-588.
- [67] 肖文娟, 王加胜. 基于 Vue 和 Spring Boot 的校园记录管理 Web App 的设计与实现[J]. 计算机应用与软件, 2020, 37: 25-30+88.